

Universidad Peruana de Ciencias Aplicadas



MACHINE LEARNING (1ACC0057)

Sección: 3037

Profesor: Jairo Pinedo Taquia

Hito 4

Informe del trabajo

Carrera de Ciencias de la Computación

Integrantes:

Ricardo Víctor Ambrocio Tantalean - u202315214

Marcelo Matías Hernández Rengifo - u202314397

Joaquín Alonso Basas Requena - u202310688

Gustavo Antonio Pérez Rojas - u202421876

Johan Sebastián Quispe Quintana - u202310543

Tabla de Contenidos

1. Resumen Ejecutivo (Executive Summary).....	3
2. Marco Metodológico: CRISP-DM Aplicado.....	5
2.1. Business Understanding.....	5
2.2. Data Understanding & Exploratory Data Analysis (EDA).....	13
2.3. Data Preparation & Feature Engineering.....	67
2.4. Modeling.....	85
2.5. Evaluation.....	96
2.5.1. Evaluación del Dataset 1: Clasificación del nivel de prioridad de atención.	96
2.5.2. Evaluación del Dataset 2: Predicción de demanda y stock crítico.....	98
2.5.3. Conclusión de la evaluación.....	99
3. Implementación y Despliegue (MLOps).....	99
3.1. Arquitectura del modelo.....	99
3.2. Pipeline de datos desde la base de datos común.....	99
3.3. Dashboard de visualización.....	100
Vista 1: Panel de gestión de pacientes.....	101
Vista 2: Panel logístico y de inventario.....	101
Vista 3: Módulo de alertas de stock crítico.....	101
3.4. Verificación y calidad del despliegue.....	102
4. Análisis de Impacto ODS y Ética de Datos.....	102
4.1. Relación con los ODS.....	102
ODS 2: Hambre cero.....	102
ODS 3: Salud y bienestar.....	103
4.2. Sesgos y ética de datos.....	104
5. Confluencia con el Ecosistema ALDIMI Core AI.....	104
5.1. Descripción técnica de la integración.....	104
5.2. Valor de la integración entre módulos.....	106
5.3. Lecciones aprendidas en la integración.....	106
6. Anexo.....	106
Diccionario de datos final.....	107
Dataset 1: Evaluaciones de pacientes.....	107
Dataset 2: Demanda y stock de insumos.....	108
7. Bibliografía.....	110

1. Resumen Ejecutivo (Executive Summary)

El presente proyecto aborda la problemática de la gestión predictiva de recursos y la priorización de atención en pacientes oncológicos en situación de vulnerabilidad, tomando como contexto institucional a la Asociación de Voluntariado de Infancia y Familia – ALDIMI. Esta organización sin fines de lucro brinda apoyo integral a pacientes oncológicos de extrema pobreza que llegan a Lima desde distintas regiones del país en búsqueda de tratamiento especializado, ofreciendo alojamiento seguro, alimentación completa y saludable, ropa, pasajes y soporte emocional para enfrentar el cáncer con dignidad (ALDIMI, s.f.).

La propuesta se centra en el desarrollo de un sistema predictivo denominado ALDIMI-Predict, orientado a apoyar la toma de decisiones en dos frentes principales: la identificación del nivel de prioridad de atención del paciente y la predicción de demanda de medicamentos e insumos. Esta orientación se alinea con el enunciado del curso, el cual solicita implementar un sistema predictivo de gestión de recursos y riesgos, considerando modelos de regresión o series temporales para predecir stock crítico a 7 y 14 días, así como modelos de clasificación supervisada para estimar el nivel de prioridad de atención en bajo, medio o alto .

El proyecto se delimita al cáncer gástrico como caso de estudio, debido a su relevancia en el contexto peruano y a su adecuación para un modelo basado en variables clínicas y sociales tabulares. De acuerdo con la *Sala situacional de cáncer en el Perú: SE 52-2023*,

elaborada por el Centro Nacional de Epidemiología, Prevención y Control de Enfermedades del Ministerio de Salud, el cáncer de estómago registra presencia tanto en hombres como en mujeres dentro de los casos notificados en el país, lo que permite justificar su selección como una problemática oncológica relevante para el Perú (CDC Perú, 2023). Además, a diferencia de otros tipos de cáncer que podrían requerir imágenes médicas, el cáncer gástrico permite trabajar con variables como edad, sexo, estadio clínico, grado histológico, metástasis, anemia, pérdida de peso, estado nutricional, síntomas y tratamiento requerido.

Debido a que no se utilizarán datos reales de pacientes de ALDIMI, el proyecto empleará datos sintéticos, contruidos a partir de criterios clínicos documentados y de una lógica epidemiológica coherente con el contexto peruano. Esta decisión permite proteger la privacidad de pacientes reales y, al mismo tiempo, simular escenarios útiles para el entrenamiento de modelos de Machine Learning. La generación de datos sintéticos no se realizará de manera aleatoria simple, sino mediante reglas clínicas controladas, considerando la progresión del cáncer gástrico, la diferencia entre estadio y grado, la presencia de metástasis, el deterioro nutricional y la demanda de medicamentos o insumos según el nivel de prioridad.

El sistema estará compuesto por dos modelos complementarios. El primer modelo será de clasificación supervisada y tendrá como objetivo predecir el nivel_prioridad del paciente en tres categorías: bajo, medio y alto. Para ello, utilizará variables clínicas y sociales como edad, región de procedencia, nivel de vulnerabilidad, estadio, grado histológico, ganglios afectados, metástasis, anemia, pérdida de peso, dolor, dificultad para alimentarse y estado funcional. Este modelo permitirá identificar qué pacientes requieren mayor seguimiento, soporte clínico, apoyo nutricional o intervención prioritaria.

El segundo modelo será de regresión o series temporales y tendrá como objetivo predecir la demanda de medicamentos e insumos a 7 y 14 días, así como detectar posibles escenarios de stock crítico. Este modelo utilizará información agregada proveniente del primer modelo, como cantidad diaria de pacientes con prioridad baja, media y alta, además de variables operativas como ocupación del albergue, consumo diario, stock actual, stock mínimo, ingresos de inventario, salidas de inventario y consumo histórico. De esta manera, el sistema permitirá estimar necesidades futuras de antieméticos, analgésicos, protectores gástricos, suplementos nutricionales, insumos postoperatorios y recursos asociados al tratamiento o soporte de pacientes con cáncer gástrico.

La integración entre ambos modelos constituye el principal valor predictivo del proyecto. El modelo de clasificación transforma la información clínica y social del paciente en una prioridad de atención, mientras que el modelo de demanda utiliza esa prioridad como insumo para proyectar el consumo de recursos. Por ejemplo, un aumento en pacientes con prioridad alta, estadio avanzado, desnutrición, dolor intenso o tratamiento paliativo puede traducirse en una mayor demanda de medicamentos, soporte nutricional y acompañamiento operativo. Así, la solución no solo predice el riesgo del paciente, sino que también permite anticipar necesidades logísticas para evitar desabastecimientos.

El valor del sistema propuesto radica en reducir la incertidumbre operativa y apoyar una gestión más preventiva de los recursos en ALDIMI. En términos técnicos, el modelo de clasificación será evaluado mediante métricas como accuracy, precision, recall y F1-score;

mientras que el modelo de regresión o series temporales será evaluado mediante MAE, RMSE y MAPE. Asimismo, el dashboard final permitirá visualizar alertas de stock, niveles de prioridad de pacientes y tendencias de consumo, en concordancia con el requerimiento del curso de entregar una herramienta de toma de decisiones basada en modelos predictivos .

Finalmente, el proyecto se vincula con el ODS 3: Salud y Bienestar, al proponer una herramienta que contribuye a una atención más oportuna y organizada para pacientes oncológicos, y con el ODS 10: Reducción de las Desigualdades, al orientar el uso de tecnología hacia personas en situación de pobreza que requieren apoyo para acceder a tratamiento especializado. Además, al trabajar con datos sintéticos, el proyecto incorpora una consideración ética importante: evitar la exposición de información sensible de pacientes reales, sin perder la posibilidad de construir y evaluar un prototipo funcional de Machine Learning aplicado a un problema socialmente relevante.

2. Marco Metodológico: CRISP-DM Aplicado

2.1. Business Understanding

Comprensión del problema de negocio

ALDIMI brinda apoyo integral a pacientes oncológicos en situación de extrema pobreza que llegan a Lima para recibir tratamiento especializado. En este contexto, uno de los principales retos operativos consiste en anticipar qué pacientes requieren mayor prioridad de atención y qué recursos serán necesarios para sostener su acompañamiento. La problemática no solo involucra el estado clínico del paciente, sino también factores sociales como región de procedencia, vulnerabilidad, necesidad de alojamiento, alimentación, traslado y soporte emocional.

El proyecto ALDIMI-Predict se plantea como un sistema predictivo de gestión de recursos y riesgos. De acuerdo con el enunciado del curso, la solución debe considerar dos frentes: la predicción de demanda y logística para optimizar inventario, y la clasificación de riesgo de salud para identificar pacientes con mayor probabilidad de complicaciones clínicas .

Asimismo, el enunciado exige implementar modelos de regresión o series temporales para predecir stock crítico a 7 y 14 días, y modelos de clasificación supervisada para clasificar el “Nivel de Prioridad de Atención” en bajo, medio o alto, usando variables clínicas y sociales .

En este proyecto, el caso de estudio se delimita al cáncer gástrico, debido a que puede representarse mediante variables clínicas tabulares sin necesidad de imágenes médicas. Además, permite modelar información relevante como estadio, grado histológico, presencia de metástasis, anemia, pérdida de peso, estado nutricional, dolor, tratamiento requerido y demanda de medicamentos o insumos. Dado que no se trabajará con datos reales de pacientes de ALDIMI, se emplearán datos sintéticos, generados con reglas clínicas y operativas controladas.

Objetivo de negocio

El objetivo de negocio es apoyar la toma de decisiones en ALDIMI mediante un sistema predictivo que permita:

1. Identificar pacientes con mayor prioridad de atención.
2. Anticipar la demanda de medicamentos e insumos.
3. Detectar posibles escenarios de stock crítico.
4. Reducir la incertidumbre operativa en la gestión de recursos.
5. Facilitar la planificación ante una ocupación proyectada de 50 a 100 familias.

En términos prácticos, el sistema busca responder dos preguntas principales:

¿Qué pacientes requieren mayor atención y seguimiento?

¿Qué cantidad de medicamentos o insumos se necesitará en los próximos 7 y 14 días?

Objetivos de Machine Learning

El proyecto tendrá dos objetivos de Machine Learning complementarios.

Objetivo ML 1: Clasificación del nivel de prioridad de atención

El primer modelo será un modelo de clasificación supervisada. Su finalidad será predecir el nivel de prioridad de atención del paciente con cáncer gástrico a partir de variables clínicas y sociales.

La variable objetivo será:

Variable objetivo	Tipo de problema	Valores posibles	¿Qué se predice?
nivel_prioridad	Clasificación multiclase	bajo, medio, alto	El nivel de prioridad de atención del paciente.

Esta predicción es importante porque permite ordenar la atención según la gravedad clínica y la vulnerabilidad social. Por ejemplo, un paciente con estadio avanzado, metástasis, anemia, desnutrición o dolor alto debería recibir mayor prioridad que un paciente en estadio inicial y con síntomas leves.

La clasificación se construirá a partir de variables como:

- edad
- sexo
- region_procedencia
- nivel_vulnerabilidad
- estadio
- grado_histologico

- ganglios_afectados
- metastasis
- perdida_peso_kg
- estado_nutricional
- hemoglobina
- anemia
- dolor
- vomitos_frecuentes
- sangrado_digestivo
- dificultad_alimentarse
- estado_funcional

Estas variables son relevantes porque el cáncer gástrico no solo afecta por la extensión del tumor, sino también por el deterioro nutricional, la presencia de síntomas, la tolerancia al tratamiento y las condiciones sociales del paciente.

Objetivo ML 2: Predicción de demanda y stock crítico

El segundo objetivo de Machine Learning corresponde a un problema de regresión o series temporales, orientado a predecir la demanda futura de medicamentos e insumos para pacientes con cáncer gástrico atendidos en el contexto de ALDIMI. Este modelo utilizará el Dataset 2, denominado `demanda_stock_insumos_cancer_gastrico_sintetico.csv`, el cual fue construido a partir del Dataset 1 mediante agregaciones diarias de pacientes activos.

Cada fila del Dataset 2 representa el comportamiento diario de un medicamento o insumo en una fecha determinada. El dataset contiene 5010 registros, distribuidos en 15 medicamentos e insumos, con 334 registros diarios por cada ítem. El rango temporal considerado va desde el 14 de marzo de 2025 hasta el 10 de febrero de 2026, permitiendo modelar patrones diarios de consumo, ocupación del albergue y variaciones de stock.

La conexión entre ambos datasets se realiza a partir de la última evaluación disponible de cada paciente activo. Para cada fecha, se agregan variables derivadas del Dataset 1, como cantidad de pacientes por prioridad, estadio, tratamiento y síntomas. De esta manera, el modelo de demanda no se genera de forma aislada, sino que depende directamente de la condición clínica y social de los pacientes clasificados previamente por el modelo de prioridad.

Las principales variables objetivo del modelo son:

Variable objetivo	Tipo de problema	Descripción	Horizonte
<code>demanda_7_dias</code>	Regresión	Cantidad estimada de unidades requeridas para los próximos 7 días por medicamento o insumo.	7 días
<code>demanda_14_dias</code>	Regresión	Cantidad estimada de unidades requeridas para los próximos 14 días por medicamento o insumo.	14 días

stock_critico_7d	Clasificación binaria / alerta derivada	Indica si el stock proyectado será insuficiente en los próximos 7 días.	7 días
stock_critico_14d	Clasificación binaria / alerta derivada	Indica si el stock proyectado será insuficiente en los próximos 14 días.	14 días
stock_critico	Clasificación binaria / alerta general	Indica si existe riesgo de stock crítico considerando cualquiera de los dos horizontes.	7 o 14 días

El catálogo de medicamentos e insumos fue corregido tomando como referencia la Guía de Práctica Clínica del INEN para cáncer gástrico. Por ello, el Dataset 2 incluye medicamentos relacionados con esquemas terapéuticos como CAPOX, FOLFOX y FLOT, así como terapia dirigida anti-HER2 y medicamentos de soporte clínico. Los ítems incluidos son: fluorouracilo_5fu, capecitabina, oxaliplatino, cisplatino, leucovorina, docetaxel, paclitaxel, carboplatino, trastuzumab, ondansetron, dexametasona, omeprazol, morfina, suplemento_nutricional e insumos_curacion_postoperatoria.

Para la predicción, el modelo utilizará variables temporales, operativas, clínicas agregadas y de inventario. Entre las variables temporales se consideran fecha, dia_semana, semana, mes y año. Entre las variables operativas se incluyen ocupacion_albergue, capacidad_albergue y porcentaje_ocupacion, manteniendo una ocupación simulada entre 50 y 100 pacientes/familias, tal como exige el planteamiento del proyecto. Entre las variables clínicas agregadas se incluyen pacientes_prioridad_baja, pacientes_prioridad_media, pacientes_prioridad_alta, pacientes_estadio_0_I, pacientes_estadio_II, pacientes_estadio_III_IV, pacientes_quimioterapia, pacientes_cirugia, pacientes_paliativos, pacientes_soporte_nutricional, pacientes_con_anemia, pacientes_con_vomitos, pacientes_dolor_alto y pacientes_desnutricion.

Asimismo, para representar mejor los esquemas oncológicos, se añadieron variables sintéticas derivadas como pacientes_quimio_curativa, pacientes_quimio_avanzada, pacientes_flot_estimado, pacientes_folfox_capox_estimado y pacientes_her2_positivo_estimado. Estas variables permiten relacionar el consumo de medicamentos antineoplásicos con la cantidad de pacientes que podrían requerir esquemas como FOLFOX, CAPOX, FLOT o terapia anti-HER2.

El modelo también utilizará variables de inventario como stock_actual, stock_minimo, ingresos_stock, salidas_stock, stock_cierre, consumo_diario, consumo_lag_1, consumo_lag_7, consumo_promedio_7d y consumo_promedio_14d. Estas variables permiten que la predicción no dependa solo del estado clínico de los pacientes, sino también del historial de consumo y disponibilidad del inventario.

La validación inicial del Dataset 2 mostró que la ocupación diaria se mantiene entre 50 y 100, que no existen valores negativos en consumo, stock ni demanda, y que la demanda proyectada a 14 días siempre es mayor o igual que la demanda proyectada a 7 días. Además, se comprobó que para cada fecha se conserva un único contexto clínico-operativo

aplicado a los 15 medicamentos, y que la distribución promedio de prioridades del Dataset 2 es coherente con la observada en el Dataset 1.

En consecuencia, este segundo modelo permitirá estimar la demanda futura de medicamentos e insumos y generar alertas de stock crítico. Su valor principal será apoyar la planificación logística de ALDIMI, anticipando posibles desabastecimientos y permitiendo una gestión preventiva de recursos según la carga clínica de los pacientes.

Relación entre ambos modelos

Ambos modelos no funcionarán de manera aislada. El primer modelo clasificará a cada paciente según su nivel de prioridad. Luego, esa información será agregada por fecha para alimentar el segundo modelo.

El flujo será el siguiente:

Evaluaciones clínicas y sociales de pacientes



Modelo de clasificación



Nivel de prioridad: bajo, medio o alto



Agregación diaria de pacientes por prioridad



Modelo de regresión o series temporales



Predicción de demanda a 7 y 14 días



Alerta de stock crítico

Por ejemplo, si aumenta la cantidad de pacientes con prioridad alta, estadio III o IV, dolor alto, desnutrición o tratamiento paliativo, el sistema debería proyectar una mayor demanda de medicamentos, suplementos nutricionales, antieméticos, analgésicos e insumos de soporte.

Criterios de éxito técnico

Los criterios de éxito técnico permiten definir cuándo el modelo será considerado aceptable para el proyecto. Estos criterios se dividen según el tipo de modelo.

Criterios de éxito para el modelo de clasificación

El modelo de clasificación será considerado exitoso si logra identificar correctamente el nivel de prioridad de los pacientes, especialmente los casos de prioridad alta, ya que estos representan mayor riesgo clínico y mayor necesidad de atención.

Métrica	Criterio mínimo esperado	Justificación
Accuracy	≥ 0.80	Permite medir el rendimiento general del modelo.
Macro F1-score	≥ 0.80	Evalúa el desempeño promedio en las tres clases sin favorecer solo a la clase mayoritaria.
Recall de prioridad alta	≥ 0.85	Es importante detectar la mayor cantidad posible de pacientes de alto riesgo.
F1-score por clase	≥ 0.75	Evita que el modelo funcione bien solo en una categoría y mal en otra.
Matriz de confusión	Errores graves reducidos	Se debe evitar clasificar pacientes de prioridad alta como prioridad baja.

El criterio más importante será el recall de la clase alta, porque en un contexto de salud es más grave no detectar a un paciente crítico que clasificar como crítico a un paciente que luego puede ser revisado.

Criterios de éxito para el modelo de regresión o series temporales

El modelo de predicción de demanda será considerado exitoso si logra estimar la cantidad de medicamentos e insumos con un margen de error aceptable para la planificación operativa.

Métrica	Criterio mínimo esperado	Justificación
MAE para demanda_7_dias	$\leq 15\%$ de la demanda promedio semanal	Un error bajo a 7 días permite tomar decisiones rápidas de reposición.
MAPE para demanda_7_dias	$\leq 15\%$	Facilita interpretar el error como porcentaje.
MAE para demanda_14_dias	$\leq 20\%$ de la demanda promedio quincenal	A 14 días se acepta un error mayor porque la incertidumbre aumenta.
MAPE para demanda_14_dias	$\leq 20\%$	Permite evaluar el rendimiento en horizonte de mediano plazo.
RMSE	Menor que el baseline	El modelo debe superar una predicción simple basada en promedio histórico.
Predicciones negativas	0 casos	No debe predecirse demanda negativa de medicamentos o insumos.

Para el horizonte de 7 días se propone un criterio más estricto, porque es una predicción de corto plazo. Para el horizonte de 14 días se acepta un margen ligeramente mayor, ya que la demanda futura puede variar más por cambios en ocupación, ingreso de pacientes y severidad clínica.

Criterios de éxito para alerta de stock crítico

La alerta de stock crítico será evaluada como una salida binaria, derivada de la comparación entre el stock disponible y la demanda proyectada.

Métrica	Criterio mínimo esperado	Justificación
----------------	---------------------------------	----------------------

Recall de stock_crítico = sí	≥ 0.90	Es fundamental detectar casi todos los casos de posible desabastecimiento.
Precision de stock_crítico = sí	≥ 0.80	Evita generar demasiadas falsas alarmas.
Falsos negativos	$\leq 5\%$	Un falso negativo implica no advertir que faltará stock.
Tiempo de anticipación	7 y 14 días	Debe permitir planificar reposiciones antes de llegar al desabastecimiento.

En este caso, el error más grave es el falso negativo, es decir, que el sistema indique que no habrá stock crítico cuando en realidad sí lo habrá. Por ello, se prioriza el recall de la alerta crítica.

Criterios de éxito del proyecto

Además de las métricas técnicas, el proyecto será exitoso si cumple con estos criterios operativos:

Criterio	Descripción
Coherencia clínica	Las variables sintéticas deben seguir reglas médicas razonables sobre cáncer gástrico, estadio, grado, síntomas y tratamiento.
Coherencia social	El dataset debe representar pacientes vulnerables provenientes de distintas regiones, en concordancia con el contexto de ALDIMI.
Integración entre modelos	La salida del modelo de clasificación debe alimentar el modelo de demanda.
Interpretabilidad	El sistema debe explicar qué variables influyen en la prioridad del paciente y en el stock.

Dashboard útil	El dashboard debe mostrar niveles de prioridad, demanda proyectada y alertas de stock.
Ética de datos	El uso de datos sintéticos debe evitar la exposición de información real sensible de pacientes.

Formulación final del problema de ML

En síntesis, el proyecto formula dos problemas de Machine Learning:

Problema 1: Clasificación supervisada

Predecir el nivel de prioridad de atención de un paciente con cáncer gástrico en bajo, medio o alto, utilizando variables clínicas y sociales generadas sintéticamente bajo criterios médicos y operativos.

Problema 2: Regresión o series temporales

Predecir la demanda de medicamentos e insumos a 7 y 14 días, y detectar stock crítico, utilizando información temporal de consumo, ocupación del albergue y cantidad de pacientes por nivel de prioridad.

2.2. Data Understanding & Exploratory Data Analysis (EDA)

Dataset de objetivo ML 1: Clasificación del nivel de prioridad de atención

1. Carga y revisión inicial del dataset

En esta primera etapa se realizó la carga del dataset sintético correspondiente a evaluaciones de pacientes con cáncer gástrico atendidos en el contexto del proyecto ALDIMI-Predict. El conjunto de datos contiene información clínica, social, demográfica, temporal, de síntomas, tratamiento y nivel de prioridad de atención.

El dataset está compuesto por 5000 registros y 41 variables. Cada fila representa una evaluación realizada a un paciente en una fecha determinada. Además, se identificaron 2000 pacientes únicos, lo que indica que algunos pacientes cuentan con más de una evaluación dentro del periodo analizado.

La variable objetivo del primer modelo predictivo es nivel_prioridad, clasificada en tres categorías: bajo, medio y alto.

2. Estructura general y tipos de datos

El dataset presenta 41 columnas distribuidas en variables de identificación, temporales, demográficas, sociales, clínicas, síntomas, tratamiento y variable objetivo. Inicialmente, las fechas estaban almacenadas como tipo object, por lo que fueron convertidas a formato datetime en una copia de trabajo llamada df_eda, sin modificar el dataset original.

En cuanto a los tipos de datos, se identificaron:

- 6 variables numéricas: dias_desde_diagnostico, dias_en_albergue, edad, ganglios_afectados, perdida_peso_kg y hemoglobina.
- 35 variables categóricas: incluyen identificadores, fechas antes de conversión, características clínicas, sociales, síntomas, tratamientos y la variable objetivo.

Esta revisión permitió comprender la estructura general del dataset y preparar las siguientes etapas del análisis exploratorio.

3. Agrupación temática de variables

Las 41 variables fueron clasificadas en grupos temáticos para facilitar el análisis:

Grupo	Cantidad de variables
Identificación	2
Temporales	5
Demográficas y sociales	9
Clínico-oncológicas	8
Síntomas y estado del paciente	11
Tratamiento	5
Variable objetivo	1

La validación mostró que todas las columnas fueron correctamente clasificadas, sin variables repetidas ni columnas sin grupo. Esta organización permitió realizar un EDA más ordenado, separando el análisis clínico, social, sintomático y predictivo.

4. Calidad de datos: nulos, duplicados y consistencia

Se revisó la presencia de valores nulos, duplicados, espacios innecesarios y rangos inválidos. El dataset no presenta registros completamente duplicados, tampoco existen duplicados en evaluacion_id, lo cual confirma que cada evaluación tiene un identificador único.

Respecto a valores nulos, se encontraron únicamente en cinco variables:

Variable	Valores nulos	Porcentaje
hemoglobina	140	2.80%
perdida_peso_kg	105	2.10%
grado_histologico	73	1.46%
sitio_metastasis	61	1.22%
estado_funcional	60	1.20%

En total, 429 filas presentan al menos un valor nulo, lo que representa el 8.58% del dataset. Sin embargo, los porcentajes de nulos por variable son bajos, por lo que no se justifica eliminar columnas ni registros de forma directa. Para la etapa de preparación de datos, se recomienda imputar estos valores de manera controlada.

También se validaron rangos numéricos y no se encontraron edades negativas, edades mayores a 100, días negativos, ganglios negativos, pérdida de peso negativa ni valores de hemoglobina fuera de rangos extremos.

Además, la relación entre metastasis y sitio_metastasis fue coherente: los pacientes sin metástasis tienen principalmente el valor ninguno, mientras que los pacientes con metástasis presentan sitios como hígado, peritoneo, pulmón o múltiples sitios.


5. Identificadores y seguimiento de pacientes

El dataset contiene 5000 evaluaciones únicas correspondientes a 2000 pacientes únicos. Esto indica que existen pacientes evaluados más de una vez, lo cual es coherente con un contexto clínico donde el estado del paciente puede cambiar en el tiempo.

La distribución de evaluaciones por paciente fue la siguiente:

Evaluaciones por paciente	Cantidad de pacientes
1 evaluación	432
2 evaluaciones	680
3 evaluaciones	473
4 evaluaciones	286
5 evaluaciones	129

El promedio fue de 2.5 evaluaciones por paciente, con un máximo de 5 evaluaciones. Esto confirma que el dataset permite observar cambios en el estado clínico y en el nivel de prioridad a lo largo del tiempo.



6. Análisis temporal



Las variables temporales analizadas fueron `fecha_diagnostico`, `fecha_ingreso_aldimi` y `fecha_evaluacion`. Después de convertirlas a formato fecha en `df_eda`, no se generaron valores nulos.


El rango temporal observado fue:

Variable	Fecha mínima	Fecha máxima
<code>fecha_diagnostico</code>	2025-01-01	2026-06-29
<code>fecha_ingreso_aldimi</code>	2025-01-09	2026-09-05
<code>fecha_evaluacion</code>	2025-01-13	2026-11-02

También se validó el orden lógico de fechas. No existen evaluaciones antes del diagnóstico, ingresos a ALDIMI antes del diagnóstico ni evaluaciones antes del ingreso a ALDIMI. Además, las variables derivadas `dias_desde_diagnostico` y `dias_en_albergue` coinciden con los cálculos realizados a partir de las fechas.

En la distribución mensual de evaluaciones se observa una menor cantidad de registros al inicio y al final del periodo, lo cual puede explicarse por los límites temporales del dataset. En los meses centrales, la cantidad de evaluaciones se mantiene más estable.





7. Análisis univariado de variables demográficas y sociales

El análisis demográfico muestra que la edad promedio de los pacientes es de 58.56 años, con una mediana de 63 años. La mayoría de evaluaciones corresponde a adultos mayores.

La distribución por grupo de edad fue:



Grupo de edad	Porcentaje
Adulto mayor	58.62%
Adulto	22.52%
Adulto joven	17.22%
Niño/adolescente	1.64%



Respecto al sexo, el dataset presenta una distribución relativamente equilibrada: 52.34% masculino y 47.66% femenino.



En cuanto a procedencia, la mayor proporción proviene de la sierra con 42.98%, seguida de la costa con 40.76% y la selva con 16.26%. Además, el 87.90% de los pacientes viaja desde provincia, lo que evidencia una fuerte presencia de pacientes desplazados hacia Lima por motivos de atención médica.



También se observa que el 84.54% cuenta con acompañante. En vulnerabilidad social, predominan los niveles alto y muy_alto, que en conjunto representan más del 75% de las evaluaciones. La dificultad de acceso a salud también se concentra en niveles alta y media.


Estos resultados son coherentes con el enfoque social del proyecto, ya que ALDIMI atiende a pacientes oncológicos en situación de vulnerabilidad y con dificultades de acceso a servicios de salud especializados.











8. Análisis univariado de variables clínico-oncológicas

Todas las evaluaciones corresponden a cáncer gástrico, por lo que `tipo_cancer` es una variable constante. Esta variable es útil para describir el alcance del dataset, pero no aporta información predictiva para el modelo, por lo que debe excluirse durante el modelado.

El tipo histológico más frecuente fue adenocarcinoma_intestinal con 49.34%, seguido de adenocarcinoma_difuso con 35.06%. Esto indica que el dataset representa principalmente casos de adenocarcinoma, lo cual es coherente con el cáncer gástrico.

La distribución por estadio clínico fue:



Estadio	Porcentaje
0	6.94%
I	23.22%
II	32.82%
III	25.96%
IV	11.06%



El estadio II fue el más frecuente, seguido por el estadio III. Esto muestra que el dataset incluye tanto casos tempranos como casos avanzados, lo cual es importante para entrenar un modelo de clasificación de prioridad.



En cuanto al grado histológico, predominan G3 con 34.18% y G2 con 32.70%. Los grados más altos representan tumores con mayor agresividad celular, por lo que pueden ser relevantes para la predicción de prioridad.



La variable ganglios_afectados tiene una media de 3.61 ganglios, mediana de 2 y máximo de 17. La distribución muestra concentración en valores bajos, pero también presencia de casos con alta afectación ganglionar.

Finalmente, el 11.06% de evaluaciones presenta metástasis, y los sitios más frecuentes son hígado, peritoneo, múltiples sitios y pulmón.









9. Análisis univariado de síntomas y estado del paciente

Las variables de síntomas y estado clínico permiten entender la condición general del paciente al momento de la evaluación.


La pérdida de peso promedio fue de 5.75 kg, con una mediana de 5.7 kg y un máximo de 16.6 kg. Esta variable es relevante porque la pérdida de peso suele estar asociada al deterioro nutricional y a mayor complejidad clínica.



La hemoglobina promedio fue de 11.91 g/dL, con una mediana de 12.0 g/dL. Además, el 67.56% de las evaluaciones presenta anemia, lo cual indica una alta frecuencia de compromiso hematológico en el dataset.



Respecto al estado nutricional, el grupo más frecuente fue riesgo, seguido de adecuado y desnutrición. Esto refuerza la importancia del soporte nutricional dentro del proyecto.



En síntomas, el dolor se distribuye principalmente entre nivel bajo y medio, aunque el dolor alto aparece en una proporción importante. También se observa presencia de vómitos frecuentes, sangrado digestivo, fatiga y dificultad para alimentarse.



En estado funcional, predominan los pacientes con estado limitado, seguidos de bueno y dependiente. Esta variable resulta importante porque refleja el grado de autonomía del paciente y su posible necesidad de atención prioritaria.


















10. Análisis univariado de variables de tratamiento



En las variables de tratamiento se observa que el 59.66% requiere cirugía, el 48.20% requiere quimioterapia, el 69.28% requiere soporte nutricional y el 13.54% requiere cuidados paliativos.


El tratamiento principal más frecuente fue cirugía, con 34.76%, seguido de cirugía_quimioterapia con 20.56% y quimioterapia con 18.22%.

La alta proporción de pacientes que requieren soporte nutricional evidencia que el componente alimentario y nutricional es una necesidad importante dentro del contexto de ALDIMI. Asimismo, la presencia de pacientes en cuidados paliativos permite representar casos de mayor complejidad clínica.










11. Análisis de la variable objetivo

La variable objetivo nivel_prioridad presenta tres clases: bajo, medio y alto.


La distribución fue:

Nivel de prioridad	Frecuencia	Porcentaje
Bajo	1520	30.40%
Medio	1790	35.80%
Alto	1690	33.80%

La distribución es relativamente equilibrada, lo cual es positivo para el modelado supervisado. No existe una clase extremadamente dominante, por lo que el modelo podrá aprender patrones de las tres categorías sin un desbalance severo.



Distribución porcentual del nivel de prioridad



12. Análisis bivariado: variables clínico-oncológicas vs nivel de prioridad

En esta etapa se analizó la relación entre las variables clínicas y la variable objetivo nivel_prioridad. Para las variables categóricas se utilizó Cramér's V, mientras que para variables numéricas se utilizó eta squared.

Los resultados muestran que las variables clínicas tienen una relación fuerte con el nivel de prioridad. La variable con mayor asociación fue estadio, con un Cramér's V de 0.856. Esto confirma que el estadio clínico es uno de los principales factores asociados al nivel de prioridad.

La distribución porcentual muestra un patrón claro:


- En estadio 0, el 97.41% corresponde a prioridad baja.
- En estadio I, el 91.90% corresponde a prioridad baja.
- En estadio II, el 89.58% corresponde a prioridad media.



- En estadio III, el 81.28% corresponde a prioridad alta.
- En estadio IV, el 100% corresponde a prioridad alta.



También se encontró una fuerte asociación entre profundidad_tumor y prioridad, con Cramér's V de 0.650. Los tumores en mucosa y submucosa se relacionan principalmente con prioridad baja, mientras que invasión local y enfermedad diseminada se asocian mayormente con prioridad alta.



La presencia de metástasis también es relevante. Los pacientes con metástasis fueron clasificados en su totalidad como prioridad alta, lo cual confirma su importancia clínica.

En cambio, tipo_histologico presentó una asociación muy baja con la prioridad, con Cramér's V de 0.031, lo que indica que el tipo histológico por sí solo no diferencia de manera importante el nivel de prioridad en este dataset.









13. Análisis bivariado: síntomas y estado del paciente vs nivel de prioridad

El análisis bivariado de síntomas muestra que varias variables del estado clínico del paciente presentan una relación importante con el nivel de prioridad.

Las variables categóricas con mayor asociación fueron:

Variable	Cramér's V
----------	------------

anemia	0.508
estado_funcional	0.499
dolor	0.437
estado_nutricional	0.378
dificultad_alimentarse	0.316

La anemia presenta una relación fuerte con la prioridad. En pacientes sin anemia, el 61.71% se ubica en prioridad baja; en cambio, en pacientes con anemia, el 46.57% pertenece a prioridad alta.

El estado funcional también es una variable relevante. Los pacientes con estado funcional bueno se concentran principalmente en prioridad baja, mientras que los pacientes dependientes se concentran en prioridad alta con 88.60%.

El dolor muestra un patrón progresivo: cuando el dolor es bajo, predomina la prioridad baja; cuando el dolor es alto, el 68.35% corresponde a prioridad alta.

En el estado nutricional también se observa una relación importante. Los pacientes con estado nutricional adecuado tienden a prioridad baja, mientras que los pacientes con desnutrición presentan 71.51% de prioridad alta.



Respecto a las variables numéricas, perdida_peso_kg y hemoglobina también muestran diferencias claras entre prioridades. La pérdida de peso promedio aumenta según la prioridad:



Prioridad	Pérdida de peso promedio
Bajo	3.19 kg
Medio	5.64 kg
Alto	8.15 kg



Por otro lado, la hemoglobina promedio disminuye conforme aumenta la prioridad:



Prioridad	Hemoglobina promedio
Bajo	12.74 g/dL
Medio	11.95 g/dL
Alto	11.12 g/dL



Esto indica que los pacientes de prioridad alta presentan mayor deterioro nutricional y hematológico.















14. Análisis bivariado: tratamiento vs nivel de prioridad

Las variables de tratamiento también presentan una relación relevante con el nivel de prioridad. La variable con mayor asociación fue `requiere_quimioterapia`, con Cramér's V de 0.551.


Los pacientes que no requieren quimioterapia se concentran principalmente en prioridad baja, mientras que los que sí requieren quimioterapia presentan mayor proporción de



prioridad alta. En específico, el 52.57% de quienes requieren quimioterapia pertenece a prioridad alta.



El tratamiento principal también presentó una asociación importante, con Cramér's V de 0.517. Los pacientes en seguimiento o cirugía se relacionan principalmente con prioridad baja, mientras que los pacientes en quimioterapia o cuidados paliativos se concentran en prioridad alta.



En cuidados paliativos, el 79.17% de los casos corresponde a prioridad alta. Esto es coherente con el hecho de que los cuidados paliativos suelen estar asociados a mayor complejidad clínica, enfermedad avanzada o necesidad de atención integral.

El soporte nutricional también se relaciona con prioridad alta. Los pacientes que requieren soporte nutricional presentan una mayor proporción de prioridad alta frente a quienes no lo requieren.









15. Análisis bivariado: variables demográficas/sociales vs nivel de prioridad


Las variables demográficas y sociales presentaron asociaciones bajas con el nivel de prioridad. Los valores de Cramér's V fueron reducidos:



Variable	Cramér's V
nivel_vulnerabilidad	0.050



viaja_desde_provincia	0.048
dificultad_acceso_salud	0.047
acompanante	0.034
grupo_edad	0.032
zona_procedencia	0.024
sexo	0.022



Esto indica que, en este dataset, el nivel de prioridad está mucho más relacionado con variables clínicas, síntomas y tratamiento que con variables demográficas o sociales.


Sin embargo, estas variables no deben descartarse automáticamente, ya que son importantes para el contexto social de ALDIMI. Aunque no expliquen fuertemente la prioridad clínica, sí pueden aportar información para comprender la vulnerabilidad del paciente y planificar recursos de apoyo.











16. Síntesis de asociaciones relevantes

Al integrar los resultados del análisis bivariado, se observa que las variables más asociadas al nivel de prioridad pertenecen principalmente a tres grupos: clínico-oncológicas, tratamiento y síntomas/estado del paciente.

Entre las variables categóricas, las más relevantes fueron:

Variable	Grupo	Asociación
estadio	Clínico-oncológica	0.856
profundidad_tumor	Clínico-oncológica	0.650
requiere_quimioterapia	Tratamiento	0.551
tratamiento_principal	Tratamiento	0.517
anemia	Síntomas/estado	0.508
estado_funcional	Síntomas/estado	0.499
metastasis	Clínico-oncológica	0.494
dolor	Síntomas/estado	0.437


Entre las variables numéricas, las más asociadas fueron:


Variable	Eta squared
ganglios_afectados	0.561

perdida_peso_kg	0.439
hemoglobina	0.318
dias_en_albergue	0.005
dias_desde_diagnostico	0.002
edad	0.000

Esto confirma que el modelo de clasificación debe dar mayor importancia a variables clínicas como estadio, profundidad tumoral, ganglios afectados, metástasis, anemia, estado funcional, pérdida de peso, hemoglobina y tratamiento.

Por el contrario, variables como edad, sexo, zona de procedencia y días desde el diagnóstico presentan menor asociación directa con la prioridad en este dataset.





17. Conclusión general del EDA

El análisis exploratorio permitió comprender la estructura, calidad y comportamiento del dataset utilizado para el primer modelo predictivo del proyecto ALDIMI-Predict. El conjunto de datos cuenta con 5000 evaluaciones, 2000 pacientes únicos y 41 variables, organizadas en dimensiones clínicas, sociales, temporales, sintomáticas y de tratamiento.

La calidad del dataset es adecuada para continuar con la etapa de preparación de datos, debido a que no presenta duplicados completos, no tiene errores lógicos en fechas, no muestra rangos inválidos y los valores nulos se mantienen en porcentajes bajos. Las variables con nulos deberán ser tratadas mediante imputación durante la etapa de Data Preparation & Feature Engineering.

El análisis univariado mostró que el dataset representa principalmente pacientes adultos mayores, con alta vulnerabilidad social, dificultades de acceso a salud y alta proporción de pacientes que viajan desde provincia. También se identificó una presencia importante de pacientes con anemia, riesgo nutricional, pérdida de peso, dolor, limitación funcional y necesidad de soporte nutricional.

La variable objetivo nivel_prioridad presenta una distribución equilibrada: 30.40% bajo, 35.80% medio y 33.80% alto. Esto es favorable para el entrenamiento de un modelo de clasificación supervisada, ya que reduce el riesgo de sesgo hacia una sola clase.

El análisis bivariado evidenció que la prioridad de atención está fuertemente relacionada con variables clínicas y de estado del paciente. Las variables más importantes fueron estadio, profundidad_tumor, ganglios_afectados, requiere_quimioterapia, tratamiento_principal, anemia, estado_funcional, metastasis, dolor, perdida_peso_kg y hemoglobina.

En cambio, las variables demográficas y sociales presentaron asociaciones bajas con la prioridad. No obstante, estas variables siguen siendo relevantes para el enfoque social del proyecto, ya que permiten comprender el contexto de vulnerabilidad y desplazamiento de los pacientes atendidos por ALDIMI.

En conclusión, el EDA confirma que el dataset es coherente, está suficientemente estructurado y contiene variables relevantes para construir un modelo de clasificación de prioridad de atención. La siguiente etapa deberá enfocarse en la limpieza controlada, imputación de nulos, codificación de variables categóricas, selección de características y preparación del conjunto de entrenamiento para el modelado supervisado.

Dataset de objetivo ML 2: Predicción de demanda y stock crítico

1. Carga y revisión inicial del dataset

Para el segundo modelo de stock se usó el dataset de demanda de insumos de stock orientado principalmente a cáncer gástrico, donde se cargó usando pandas para una posterior revisión de valores atípicos y nulos. El dataset inicial posee 51 variables y 5010 registros, en los cuales cada columna representa un consumo de elementos en un periodo de 7 o 14 días. Así mismo se presentan cantidades de almacenamiento de medicamentos y el estado en el que se encuentre el paciente.

2. Estructura general y tipos de datos

El dataset presenta 50 columnas distribuidas en variables de identificación, almacenamiento, clínicas, síntomas y variable objetivo. Inicialmente, las fechas estaban almacenadas como tipo object, por lo que fueron convertidas a formato datetime, sin modificar el dataset original. En cuanto a tipo de dato se observaron 41 variables numéricas y 10 de tipo objeto.

3. Variables Principales

Dentro del dataset obtuvimos las siguientes variables

Variables de Stock

- stock_actual: Nivel de inventario disponible en cada registro.
- stock_minimo: Umbral mínimo de stock requerido.
- stock_cierre: Stock al cierre del período.
- stock_proyectado_7d / stock_proyectado_14d: Proyecciones a 7 y 14 días.
- stock_critico / stock_critico_7d / stock_critico_14d: Indicadores booleanos de stock en nivel crítico.

Variables de Consumo y Demanda

- consumo_diario: Unidades consumidas por día.

- consumo_promedio_7d: Promedio móvil de consumo en los últimos 7 días.
- demanda_7_dias / demanda_14_dias: Demanda proyectada a 7 y 14 días (variable objetivo en regresión).
- ingresos_stock / salidas_stock: Movimientos de inventario.

Variables de Contexto Hospitalario


- ocupacion_albergue / porcentaje_ocupacion: Nivel de ocupación del albergue oncológico.
- pacientes_total: Número total de pacientes activos.
- pacientes_prioridad_alta / media / baja: Segmentación por urgencia clínica.
- pacientes_estadio_0_I / II / III_IV: Distribución por estadio oncológico.
- pacientes_quimioterapia / cirugía / paliativos: Tipo de tratamiento activo.

Variables Temporales y Categóricas

- fecha: Fecha del registro (convertida a tipo datetime).
- dia_semana / mes: Atributos temporales derivados.
- item_id / item_nombre / categoria_item: Identificadores del insumo.
- tipo_stock / unidad_medida: Clasificación del insumo.

4. Resultados obtenidos (EDA)

4.1 Consumo total de suplemento nutricional por semana




Este gráfico desglosa el volumen total acumulado del ítem más consumido según el día de la semana.

Distribución Homogénea: A diferencia de la alta volatilidad diaria vista en el primer gráfico, el consumo total acumulado es bastante estable a lo largo de toda la semana.

Días Pico y Valle: Los días lunes y viernes presentan los volúmenes ligeramente más altos (superando las 2500 unidades), mientras que los jueves y domingos muestran una leve disminución. Sin embargo, la variación entre el día de mayor y menor consumo es mínima.

Contexto (según la tabla): Este ítem se dispensa en sobres. Su estabilidad sugiere que el soporte nutricional es una indicación constante que no depende fuertemente de los días hábiles de intervenciones, sino del cuidado continuo del paciente.

4.2 tendencia de consumo diario de los 5 ítems mas consumidos



Este gráfico muestra la evolución diaria del consumo de los cinco productos principales entre marzo de 2025 y principios de 2026.

Tendencia General: Existe una clara tendencia al alza en el consumo de los cinco ítems a lo largo del año. Esto sugiere un aumento constante en el volumen de pacientes atendidos o en la demanda de estos tratamientos específicos.

Volatilidad Diaria: Se observan picos y valles muy pronunciados de un día para otro, lo que indica que el consumo diario no es estático y varía significativamente, probablemente dependiendo de las programaciones de cirugías o sesiones de tratamiento.


Jerarquía de Consumo:

El suplemento_nutricional (línea azul) es consistentemente el ítem más demandado, alcanzando picos cercanos a las 70 unidades diarias hacia finales de 2025.

Le siguen los insumos_curacion_postoperatoria (naranja) y el ondansetron (verde).

La dexametasona (roja) y el omeprazol (morada) mantienen los volúmenes más bajos dentro de este top 5.

4.3 Consumo total de insumos de curación post operatoria por día de semana



Este gráfico muestra el acumulado semanal para el segundo ítem de mayor demanda.

Comportamiento Estable: Al igual que el suplemento nutricional, el consumo de los kits de curación se mantiene muy constante de lunes a domingo.

Ligeras Variaciones: El martes y el viernes parecen ser los días con un consumo marginalmente superior (alrededor de 2000 unidades), mientras que los fines de semana (sábado y domingo) presentan una muy ligera caída.

Contexto (según la tabla): Estos insumos se dispensan en kits. La constancia durante el fin de semana indica que las curaciones postoperatorias son procedimientos de rutina ininterrumpidos en el área de hospitalización o recuperación.

4.4 Resumen de insumos disponibles

	item_nombre	categoria_item	unidad_medida
0	fluorouracilo_5fu	fluoropirimidina_iv	viales
1	capecitabina	fluoropirimidina_oral	tabletas
2	oxaliplatino	platino_oxaliplatino	viales
3	cisplatino	platino_cisplatino	viales
4	leucovorina	leucovorina	viales
5	docetaxel	taxano_docetaxel	viales
6	paclitaxel	taxano_paclitaxel	viales
7	carboplatino	platino_carboplatino	viales
8	trastuzumab	anti_her2	viales
9	ondansetron	antiemetico	ampollas
10	dexametasona	corticoide_antiemetico	ampollas
11	omeprazol	protector_gastrico	tabletas
12	morfina	opioide	ampollas
13	suplemento_nutricional	nutricional	sobres
14	insumos_curacion_postoperatoria	curacion	kits

Aunque es una tabla de datos, proporciona el contexto fundamental para entender las gráficas anteriores:

Perfil del Servicio: La lista incluye quimioterapias (fluorouracilo, capecitabina, oxaliplatino, cisplatino, docetaxel, etc.), junto con antieméticos (ondansetron, dexametasona), protectores gástricos (omeprazol) y opioides (morfina). Esto indica claramente que los datos provienen de un servicio de oncología o un área de cirugía oncológica.

Explicación del Top 5: Tiene sentido médico que los ítems más consumidos no sean los quimioterápicos en sí (que se aplican en ciclos espaciados), sino los insumos de soporte diario: suplementos nutricionales para pacientes oncológicos, kits de curación para postoperados, y medicamentos para el manejo de síntomas diarios (náuseas con ondansetron/dexametasona y protección gástrica con omeprazol).

2.3. Data Preparation & Feature Engineering

Dataset de objetivo ML 1: Clasificación del nivel de prioridad de atención

DP-01. Separación inicial de variables

En esta etapa se preparó la estructura base para el modelado supervisado. Se separó la variable objetivo nivel_prioridad, debido a que esta representa la clase que el modelo debe

aprender a predecir: bajo, medio o alto. También se retiraron variables que no aportan información predictiva útil o que pueden introducir ruido, como `evaluacion_id`, `paciente_id`, las fechas crudas y `tipo_cancer`.

La exclusión de `evaluacion_id` y `paciente_id` fue necesaria porque son identificadores administrativos, no características clínicas o sociales del paciente. Si se mantuvieran, el modelo podría memorizar registros en lugar de aprender patrones reales. Las fechas crudas también fueron excluidas porque ya existen variables temporales derivadas, como `dias_desde_diagnostico` y `dias_en_albergue`, que representan mejor la información temporal. Finalmente, `tipo_cancer` fue retirado porque todos los registros corresponden a cáncer gástrico, por lo que no aporta variabilidad al modelo.

Después de esta etapa, el dataset quedó organizado en una matriz de predictores `X_raw` con 5000 registros y 34 variables, y una variable objetivo y con 5000 valores.



DP-02. División train/test e imputación de valores nulos


La división del dataset en entrenamiento y prueba se realizó antes de aplicar transformaciones definitivas para evitar fuga de información. El conjunto de entrenamiento quedó con 3999 registros, y el conjunto de prueba con 1001 registros. Además, la división se hizo considerando el `paciente_id` como grupo, con el fin de evitar que evaluaciones de un mismo paciente aparezcan simultáneamente en entrenamiento y prueba.

Esta decisión es clave porque el dataset contiene varias evaluaciones por paciente. Si el mismo paciente apareciera en ambos conjuntos, el modelo podría aprender patrones propios de ese paciente y aparentar un mejor rendimiento del que realmente tendría con pacientes nuevos. La validación mostró 0 pacientes compartidos, por lo que la separación fue adecuada.

Luego se trataron los valores nulos. Como los porcentajes de datos faltantes eran bajos, se decidió imputar en lugar de eliminar registros. Eliminar filas habría reducido información clínica útil sin necesidad. En variables numéricas, como `hemoglobina` y `perdida_peso_kg`, se usó la mediana porque es robusta ante valores extremos. En variables categóricas, como `grado_histologico` y `estado_funcional`, se usó la categoría desconocido, porque permite conservar el registro sin inventar una categoría clínica. En `sitio_metastasis`, se aplicó una regla lógica basada en `metastasis`, para mantener coherencia médica.

Al finalizar, tanto entrenamiento como prueba quedaron con 0 valores nulos.






DP-03. Clasificación de variables según técnica de preprocesamiento

En esta etapa se clasificaron las variables según la transformación que debían recibir. Esto fue necesario porque aplicar la misma codificación a todas las variables sería metodológicamente incorrecto. Las variables numéricas, binarias, ordinales y nominales representan información distinta y deben prepararse de manera diferente.

Las variables numéricas se mantuvieron para posterior estandarización. Las variables binarias se prepararon para codificación 0/1. Las variables ordinales se identificaron porque tienen una jerarquía lógica o clínica, como estadio, dolor, fatiga o estado_funcional. Las variables nominales, como region_procedencia o tipo_histologico, se separaron para aplicar One-Hot Encoding, ya que no tienen un orden natural.

La validación confirmó que las 34 variables predictoras fueron correctamente clasificadas: 6 numéricas, 11 binarias, 11 ordinales y 6 nominales. No quedaron variables sin asignar ni repetidas.




DP-04. Codificación de variables binarias

Las variables binarias fueron transformadas de texto a valores numéricos usando la regla no = 0 y si = 1. Esta transformación fue necesaria porque los modelos de Machine Learning no trabajan directamente con valores textuales.

La codificación binaria se aplicó a variables como metastasis, anemia, requiere_quimioterapia, requiere_cirugia, vomitos_frecuentes y otras variables con respuesta dicotómica. Esta transformación conserva el significado original de la variable y permite que el modelo interprete la ausencia o presencia de una condición clínica, social o terapéutica.

Después de la codificación, todas las variables binarias quedaron representadas únicamente con valores 0 y 1, sin generar valores nulos. Esto confirma que las categorías estaban limpias y eran consistentes en entrenamiento y prueba.




DP-05. Codificación de variables ordinales

La codificación ordinal se aplicó a variables que tienen un orden natural o clínico. Esta decisión fue necesaria porque variables como estadio, profundidad_tumor, dolor, fatiga, estado_nutricional y estado_funcional no son categorías aisladas, sino niveles progresivos de severidad o deterioro.

Por ejemplo, estadio fue codificado de 0 a 4, respetando la progresión clínica desde estadio 0 hasta estadio IV. De forma similar, dolor fue codificado como bajo, medio y alto; y estado_nutricional como adecuado, riesgo y desnutrición. Esta codificación permite que el modelo conserve la idea de aumento de gravedad.

En las variables con categoría desconocido, se utilizó el valor -1. Esta decisión permite diferenciar los datos no registrados de las categorías clínicas reales, evitando que el modelo interprete un dato faltante como si fuera una condición médica válida.

La validación confirmó que no se generaron valores nulos y que las codificaciones fueron consistentes en entrenamiento y prueba.




DP-06. One-Hot Encoding de variables nominales

Las variables nominales fueron transformadas mediante One-Hot Encoding porque no tienen un orden natural. Variables como `region_procedencia`, `sexo`, `zona_procedencia`, `tipo_histologico`, `sitio_metastasis` y `tratamiento_principal` no deben codificarse como 0, 1, 2 o 3 de forma ordinal, porque eso implicaría falsamente que una categoría es mayor o menor que otra.

El One-Hot Encoding permitió convertir cada categoría en una columna binaria independiente. Esto evita introducir jerarquías artificiales y permite que el modelo evalúe la presencia o ausencia de cada categoría.

La transformación generó 40 columnas nuevas, siendo `region_procedencia` la variable que más columnas produjo, debido a sus 19 categorías. Después de esta etapa, el dataset pasó de 34 a 68 variables. Además, se verificó que no quedaran columnas tipo texto ni valores nulos.





DP-07. Estandarización de variables numéricas

La estandarización se aplicó a las variables numéricas originales porque estaban en escalas diferentes. Por ejemplo, `dias_desde_diagnostico` tiene valores mucho más grandes que `hemoglobina`, y `edad` tiene una escala distinta a `ganglios_afectados`.

Si no se estandarizan, algunos modelos pueden dar más importancia a las variables con valores numéricos grandes, aunque clínicamente no sean más relevantes. Por ello, se utilizó `StandardScaler` para transformar las variables numéricas a una escala comparable, centrada alrededor de 0 y con desviación estándar cercana a 1.

El escalador se ajustó únicamente con el conjunto de entrenamiento para evitar fuga de información. Esto significa que el conjunto de prueba fue transformado usando los parámetros aprendidos del entrenamiento, simulando mejor un escenario real con datos nuevos.



DP-08. Creación de nuevas variables derivadas

En esta etapa se aplicó Feature Engineering, creando 13 nuevas variables a partir de combinaciones clínicas, nutricionales, sintomáticas, terapéuticas y sociales. Esta etapa fue necesaria porque algunas condiciones no se explican bien con una sola variable, sino con la combinación de varios factores.


Por ejemplo, `indice_avance_oncologico` combina estadio, profundidad tumoral, metástasis y ganglios afectados. Esta variable resume mejor la gravedad oncológica del paciente. `indice_deterioro_nutricional` integra estado nutricional, dificultad para alimentarse, pérdida

de peso y soporte nutricional. De igual manera, conteo_sintomas_relevantes resume la acumulación de síntomas importantes.

También se crearon variables binarias como enfermedad_avanzada, alta_carga_ganglionar, perdida_peso_alta, hemoglobina_baja y tratamiento_alta_complejidad, porque estas representan condiciones clínicas claras que pueden aumentar la prioridad de atención.

Aunque las variables sociales mostraron menor asociación durante el EDA, se mantuvieron variables derivadas como vulnerabilidad_social_alta y riesgo_social_sin_acompanante, porque el contexto de ALDIMI no solo es clínico, sino también social.

Después de esta etapa, el dataset pasó de 68 a 81 variables, sin generar valores nulos.




DP-09. Escalamiento final después del Feature Engineering

Después de crear nuevas variables, fue necesario realizar un escalamiento final. Esto se hizo porque algunas variables derivadas, como indice_avance_oncologico, indice_deterioro_nutricional, conteo_sintomas_relevantes y conteo_necesidades_tratamiento, son variables numéricas nuevas y tienen escalas diferentes.

Si solo se hubieran escalado las variables numéricas originales, las variables creadas en el Feature Engineering habrían quedado en otra escala, lo que podría afectar especialmente a modelos sensibles a la magnitud de los datos, como la Regresión Logística.

Por esa razón, se estandarizaron tanto las variables numéricas originales como las nuevas variables derivadas de tipo índice o conteo. El escalador se ajustó nuevamente solo con entrenamiento. Al finalizar, X_train_final y X_test_final quedaron con 81 variables, sin nulos y sin columnas de texto.




DP-10. Revisión de desbalance de clases

En esta etapa se evaluó si era necesario aplicar técnicas de balanceo como SMOTE. Esta revisión fue importante porque la variable objetivo nivel_prioridad tiene tres clases, y un desbalance fuerte podría hacer que el modelo favorezca la clase mayoritaria.

Sin embargo, la distribución fue bastante equilibrada. En entrenamiento, la clase medio tuvo 1427 registros, alto tuvo 1383 y bajo tuvo 1189. El ratio de desbalance fue 1.2, lo cual indica un desbalance bajo.

Por esta razón, no se aplicó SMOTE inicialmente. Esta decisión es importante porque SMOTE genera datos sintéticos, y cuando el desbalance no es severo puede introducir información artificial innecesaria. En este caso, es más coherente entrenar primero con los datos originales y evaluar si realmente existe dificultad para detectar alguna clase.

Además, como el objetivo del proyecto es identificar pacientes de prioridad alta, la evaluación del modelo no se centrará principalmente en accuracy, sino en el recall de la clase alta. SMOTE solo se consideraría después si el modelo no logra detectar adecuadamente los casos de prioridad alta.



DP-11. Selección de características orientada a modelos

La selección de características se realizó considerando los dos modelos candidatos: Regresión Logística Multinomial y Random Forest. Esta decisión fue necesaria porque ambos modelos aprenden de forma diferente y, por lo tanto, no necesariamente necesitan las mismas variables.

La Regresión Logística es un modelo más interpretable y lineal. Por eso tiende a priorizar variables con efectos directos sobre la clasificación, como `enfermedad_avanzada`, `requiere_quimioterapia`, `requiere_cuidados_paliativos`, `estadio`, `metastasis` y categorías específicas de `tratamiento_principal`. Estas variables ayudan al modelo a separar las clases mediante pesos directos.

Random Forest, en cambio, funciona mediante árboles de decisión y puede capturar relaciones no lineales, interacciones y puntos de corte. Por eso priorizó variables como `estadio`, `indice_avance_oncologico`, `ganglios_afectados`, `profundidad_tumor`, `alta_carga_ganglionar`, `perdida_peso_kg`, `hemoglobina` y `estado_funcional`. Estas variables pueden funcionar mejor mediante reglas, por ejemplo, cuando la pérdida de peso supera cierto umbral o cuando la carga ganglionar es alta.


Se encontraron 19 variables comunes entre ambos modelos. Esto es importante porque indica que esas variables son relevantes independientemente del tipo de algoritmo. Las variables comunes están relacionadas con avance oncológico, estado funcional, síntomas, deterioro nutricional y complejidad del tratamiento. Por eso se consideran factores centrales del problema.



También se identificaron 11 variables solo seleccionadas por Regresión Logística. Estas corresponden principalmente a categorías específicas de tratamiento, síntomas puntuales o

contexto social. Esto ocurre porque la Regresión Logística asigna pesos individuales a cada variable, por lo que algunas categorías pueden ayudar a diferenciar directamente una clase.

Por otro lado, las 11 variables solo seleccionadas por Random Forest son principalmente variables clínicas continuas o derivadas, como profundidad_tumor, perdida_peso_kg, hemoglobina, edad, dias_desde_diagnostico, dias_en_albergue, alta_carga_ganglionar y perdida_peso_alta. Estas variables son útiles para Random Forest porque este modelo puede aprovechar cortes, umbrales e interacciones.

Esta etapa permitió construir dos versiones seleccionadas del dataset: una para Regresión Logística y otra para Random Forest, ambas con 30 variables.





DP-12. Consolidación final para modelado

En esta etapa se validaron formalmente los conjuntos finales que se usarán en la fase de Modeling. La validación confirmó que todos los datasets tienen el número correcto de filas, no presentan valores nulos y no contienen columnas de texto.

Dataset	Filas	Columnas	Nulos	Columnas de texto
X_train_final	3999	81	0	0
X_test_final	1001	81	0	0
X_train_lr_selected	3999	30	0	0
X_test_lr_selected	1001	30	0	0
X_train_rf_selected	3999	30	0	0
X_test_rf_selected	1001	30	0	0

Esta validación demuestra que los datos están listos para entrenar modelos. Se conserva una versión completa con 81 variables y dos versiones seleccionadas de 30 variables, adaptadas a cada modelo candidato.

Cierre de Data Preparation & Feature Engineering

La etapa de Data Preparation & Feature Engineering permitió transformar el dataset inicial en conjuntos listos para el modelado. Cada transformación tuvo un propósito específico: evitar fuga de información, tratar nulos sin perder registros, convertir variables categóricas a formato numérico, conservar jerarquías clínicas, evitar órdenes artificiales en variables nominales, estandarizar escalas, crear variables derivadas con sentido clínico-social, revisar el balance de clases y seleccionar características según los modelos candidatos.

Con esto, los datos quedan preparados para la siguiente fase: Modeling, donde se entrenarán y compararán Regresión Logística Multinomial y Random Forest, priorizando como métrica principal el recall de la clase alto, debido a que el error más crítico sería no identificar correctamente a un paciente que requiere atención prioritaria.

Dataset de objetivo ML 2: Predicción de demanda y stock crítico

Para el segundo objetivo del proyecto, se realizó un análisis exhaustivo del dataset orientado a la logística y el abastecimiento del albergue. A diferencia del primer dataset enfocado en evaluaciones clínicas, este posee una naturaleza de serie temporal diaria, lo que requiere un tratamiento estadístico centrado en la continuidad y la tendencia.

1. Carga y Descripción del Dataset


El dataset `demanda_stock_insumos_cancer_gastrico_sintetico.csv` registra el flujo diario de 15 tipos de insumos y medicamentos críticos (como Cisplatino, Ondansetrón y suplementos nutricionales) durante el periodo de marzo 2025 a febrero 2026. Consta de 5,010 registros y

22 columnas iniciales que capturan tanto el estado del inventario como la dinámica operativa del albergue.

2. Calidad de Datos y Limpieza

Se validó la integridad de la información mediante las siguientes acciones:

- Nulos y Duplicados: No se detectaron valores ausentes ni registros duplicados, asegurando la continuidad de las series.
- Tratamiento de Valores Negativos: Dado que el stock y el consumo no pueden ser negativos, se aplicó una técnica de clipping forzando a cero cualquier valor menor a dicha cifra, corrigiendo inconsistencias en las columnas de ingresos_stock y salidas_stock.
- Gestión de Atípicos (Outliers): Se identificaron valores extremos en consumo_diario y salidas_stock mediante el método del Rango Intercuartílico (IQR). Para no romper la secuencia temporal eliminando filas, se optó por un Capping (Winsorization), limitando los valores al límite superior de $1.5 * IQR$.



3. Agrupación Temática de Variables


Para facilitar el análisis bivariado, las variables se categorizaron en tres dimensiones:

- Inventario (Stock): stock_actual, stock_minimo, stock_proyectado_7d.
- Flujo Operativo: consumo_diario, ingresos_stock, salidas_stock, neto_movimiento.
- Indicadores del Albergue: porcentaje_ocupacion, pacientes_prioridad_alta, pacientes_prioridad_media.

4. Feature Engineering (Ingeniería de Características)

Para mejorar la capacidad predictiva de los modelos, se derivaron variables críticas que transforman datos brutos en indicadores de decisión logística:


- Días de Cobertura (dias_cobertura): Calculado como $\text{stock_actual} / (\text{consumo_diario} + 0.1)$. Es la variable de mayor valor estratégico para predecir quiebres de stock.
- Ratio de Stock Mínimo: Relación porcentual entre el stock actual y el mínimo de seguridad.
- Variables Binarias de Alerta: es_ocupacion_alta (basada en el percentil 75 de ocupación) para capturar periodos de estrés operativo.



5. Análisis Univariado y de la Variable Objetivo

Se analizó la distribución de las variables que el modelo deberá predecir:


- Regresión (demanda_7_dias y demanda_14_dias): Presentan distribuciones con sesgo a la derecha, lo que indica que el modelo debe estar preparado para manejar picos de demanda inusuales.
- Clasificación (stock_critico): Se observó que aproximadamente el 15% de los registros caen en categoría crítica, lo que representa un dataset ligeramente desbalanceado que requerirá atención durante el entrenamiento del modelo.



6. Análisis Bivariado y Correlaciones


Mediante una matriz de correlación de Pearson, se confirmaron las siguientes asociaciones clave:

- Ocupación vs. Consumo: Existe una correlación positiva fuerte ($r > 0.85$) entre el porcentaje_ocupacion y el consumo_diario, validando que la dinámica del albergue es el motor principal de la demanda.
- Pacientes Críticos: La cantidad de pacientes_prioridad_alta muestra una relación directa con las salidas_stock, lo que permite usar los datos clínicos del Dataset 1 como predictores de consumo en este Dataset 2.



7. Análisis Longitudinal (Series de Tiempo)

Al graficar el comportamiento temporal, se identificó una ciclicidad mensual en los ingresos de stock, mientras que el consumo muestra una variabilidad diaria ligada al flujo de pacientes.



8. Conclusión del EDA

El proceso de Data Understanding permitió transformar un registro de inventario plano en una estructura preparada para el aprendizaje automático. La identificación de la variable "Días de Cobertura" y la limpieza de valores imposibles garantizan que el modelo de predicción de demanda se base en datos físicamente coherentes y operativamente relevantes para la toma de decisiones en ALDIMI.

2.4. Modeling

Modeling de objetivo ML 1: Clasificación del nivel de prioridad de atención

El Objetivo ML 1 corresponde a un problema de clasificación supervisada multiclase, porque se busca predecir el nivel_prioridad de atención del paciente en tres categorías: bajo, medio y alto. Este modelo forma parte del sistema ALDIMI-Predict y tiene como finalidad apoyar la identificación de pacientes con cáncer gástrico que requieren mayor seguimiento clínico, nutricional o social. La variable objetivo definida para este modelo es nivel_prioridad, y sus valores posibles son bajo, medio y alto.

Etapa 1. Verificación de datasets preparados para Modeling

Antes de entrenar los modelos baseline, se realizó una verificación de los conjuntos de datos preparados en la etapa de Data Preparation & Feature Engineering. Esta revisión fue necesaria para confirmar que los datos estuvieran listos para ser utilizados por los algoritmos de Machine Learning, sin necesidad de realizar transformaciones adicionales durante el modelado.

En esta etapa se revisaron las dimensiones de los datasets, la presencia de valores nulos, la existencia de columnas de texto y la distribución de la variable objetivo. Los conjuntos finales utilizados para el modelado fueron X_train_final, X_test_final, X_train_lr_selected, X_test_lr_selected, X_train_rf_selected, X_test_rf_selected, y_train y y_test. La preparación

previa dejó una versión completa con 81 variables y dos versiones seleccionadas de 30 variables, una para Regresión Logística Multinomial y otra para Random Forest.

La validación mostró que los conjuntos no presentaban valores nulos ni columnas de texto. Esto confirma que las variables categóricas ya habían sido codificadas, las variables numéricas escaladas cuando correspondía y los valores faltantes tratados previamente. Además, se verificó que las dimensiones fueran coherentes: el conjunto de entrenamiento contiene 3999 registros y el conjunto de prueba 1001 registros.

La distribución de la variable objetivo también fue revisada. En el conjunto de entrenamiento, la clase medio representó el 35.68%, la clase alto el 34.58% y la clase bajo el 29.73%. En el conjunto de prueba, la clase medio representó el 36.26%, la clase bajo el 33.07% y la clase alto el 30.67%. Estos resultados muestran que las tres clases están presentes en ambos conjuntos y que no existe un desbalance severo.

Conclusión de la Etapa 1

Los datasets se encuentran preparados para iniciar el baseline del modelado. No se identificaron valores nulos ni columnas de texto, y la variable objetivo mantiene sus tres clases: bajo, medio y alto. Además, la distribución de clases es suficientemente equilibrada, por lo que no fue necesario aplicar técnicas de balanceo en esta etapa. Por tanto, se puede continuar con el entrenamiento de modelos baseline.

Etapa 2. Baseline: presentación de modelos iniciales y métricas de desempeño iniciales



En esta etapa se entrenaron modelos iniciales con el objetivo de establecer una primera referencia de desempeño. Esta fase corresponde al baseline, por lo que todavía no se busca seleccionar el modelo final ni realizar ajuste de hiperparámetros. El propósito principal es comparar modelos iniciales y observar si estos logran aprender patrones relevantes a partir de las variables clínicas y sociales preparadas.



Se utilizaron tres modelos iniciales. El primero fue un Dummy Classifier, empleado como referencia mínima. Este modelo no aprende patrones reales del dataset, sino que predice siguiendo una regla simple, por lo que sirve para comparar si los modelos supervisados realmente aportan valor. El segundo modelo fue una Regresión Logística Multinomial, seleccionada por ser un modelo interpretable y adecuado para problemas de clasificación multiclase. El tercer modelo fue un Random Forest Classifier, elegido porque puede capturar relaciones no lineales e interacciones entre variables clínicas, síntomas, tratamientos y variables derivadas.

La comparación inicial incluyó métricas como accuracy, precision, recall, F1-score, Macro F1-score y matriz de confusión. En esta etapa, estas métricas se presentan como métricas de desempeño iniciales, no como métricas principales definitivas. Esto es importante porque el baseline solo busca mostrar el comportamiento inicial de los modelos.

Los resultados mostraron que el Dummy Classifier obtuvo un accuracy de 0.3626, un recall de la clase alto de 0.0000 y un F1 macro de 0.1774. Esto indica que el modelo no logró identificar ningún paciente de prioridad alta y solo funciona como referencia mínima. En

cambio, la Regresión Logística Multinomial obtuvo un accuracy de 0.8791, un recall alto de 0.9153 y un F1 macro de 0.8806. Por su parte, Random Forest obtuvo un accuracy de 0.8791, un recall alto de 0.9055 y un F1 macro de 0.8810.





Conclusión de la Etapa 2

Los resultados del baseline muestran que los modelos supervisados superan claramente al Dummy Classifier. Esto indica que las variables preparadas sí contienen información útil para clasificar el nivel de prioridad de atención. Tanto la Regresión Logística Multinomial como Random Forest presentan un desempeño inicial alto y muy similar, por lo que ambos modelos son candidatos válidos para el análisis comparativo del baseline.

Etapla 3. Análisis del baseline y errores críticos

Después de presentar las métricas iniciales, se realizó un análisis más detallado del baseline, poniendo especial atención en la clase alto. Esta revisión es necesaria porque el problema no tiene el mismo costo de error para todas las clases. En el contexto del proyecto, clasificar incorrectamente a un paciente de prioridad alta como prioridad media o baja puede ser más grave que equivocarse entre clases menos críticas.

En esta etapa se utilizó el recall de la clase alto como métrica de enfoque para el análisis, no como selección final del modelo. Se revisó esta métrica porque permite medir cuántos pacientes realmente pertenecientes a la clase alto fueron detectados correctamente por el modelo. En otras palabras, responde a la pregunta más importante del problema: ¿el modelo está identificando a los pacientes que realmente requieren mayor prioridad de atención?



No se usó el accuracy como métrica central del análisis porque el accuracy mide el porcentaje total de aciertos, pero puede ocultar errores graves en una clase específica. Por ejemplo, un modelo podría tener buen accuracy general y aun así fallar en detectar pacientes de prioridad alta. En este caso, ese error sería delicado porque implicaría subestimar a pacientes con mayor necesidad de atención.

Tampoco se usó la precision de la clase alto como métrica de enfoque principal, porque la precision responde a otra pregunta: de todos los pacientes que el modelo predijo como prioridad alta, cuántos realmente eran prioridad alta. Aunque esta información es útil, en este contexto es más importante reducir los falsos negativos de la clase alto. Es preferible que el sistema alerte algunos casos adicionales que dejar de identificar pacientes que realmente necesitan mayor atención.

El F1-score de la clase alto y el Macro F1-score se revisaron como métricas complementarias. El F1-score ayuda a observar el equilibrio entre precision y recall de la clase alto, mientras que el Macro F1-score permite comprobar si el modelo mantiene un rendimiento equilibrado en las tres clases. Sin embargo, para analizar errores críticos, el recall de la clase alto resulta más directo, porque muestra la capacidad del modelo para detectar pacientes prioritarios.

En los resultados obtenidos, la Regresión Logística Multinomial alcanzó un recall alto de 0.9153, mientras que Random Forest obtuvo 0.9055. La diferencia entre ambos modelos en recall alto fue de 0.0098, favorable a la Regresión Logística. Sin embargo, Random Forest presentó una precision alto ligeramente mayor y un F1 macro apenas superior, aunque las diferencias fueron pequeñas.

El análisis de errores críticos mostró que, de los 307 pacientes reales de prioridad alta, la Regresión Logística clasificó correctamente 281, confundió 25 como prioridad media y 1 como prioridad baja. En cambio, Random Forest clasificó correctamente 278 pacientes de prioridad alta, confundió 29 como prioridad media y no clasificó ningún caso alto como bajo. Esto significa que la Regresión Logística detectó más pacientes de prioridad alta, pero Random Forest evitó el error más severo: clasificar un paciente alto como bajo.



Conclusión de la Etapa 3

El análisis del baseline confirma que la Regresión Logística Multinomial y Random Forest son modelos competitivos para clasificar el nivel de prioridad de atención. La Regresión Logística obtuvo el mejor recall de la clase alto, lo que indica una mayor capacidad para detectar pacientes realmente prioritarios. Sin embargo, Random Forest tuvo la ventaja de no cometer errores del tipo alto → bajo, lo cual también es relevante desde el punto de vista del riesgo.

Por ello, para esta entrega se concluye que ambos modelos supervisados presentan un desempeño inicial adecuado y superan ampliamente al Dummy Classifier. La Regresión Logística destaca por detectar más casos de prioridad alta, mientras que Random Forest muestra un comportamiento ligeramente más seguro frente al error crítico de subestimar severamente a un paciente alto. Esta fase cumple con la presentación del baseline solicitado, incluyendo modelos iniciales, métricas de desempeño iniciales y análisis de errores relevantes.

Cierre general del baseline

En conjunto, la etapa de Modeling del Objetivo ML 1 permitió construir y evaluar modelos baseline para la clasificación del nivel de prioridad de atención. Primero, se verificó que los datasets preparados estuvieran listos para modelado. Luego, se entrenaron tres modelos iniciales: Dummy Classifier, Regresión Logística Multinomial y Random Forest Classifier. Finalmente, se analizaron sus métricas de desempeño iniciales y los errores más relevantes en la clase de prioridad alta.

El Dummy Classifier confirmó el rendimiento mínimo esperado de un modelo sin aprendizaje real. En contraste, la Regresión Logística Multinomial y el Random Forest Classifier alcanzaron resultados superiores, con accuracy cercano a 0.88 y F1 macro también cercano a 0.88. Estos resultados evidencian que las variables clínicas, sociales y derivadas generadas en la preparación de datos aportan información útil para clasificar la prioridad de atención.

Para esta entrega, no se realiza todavía ajuste de hiperparámetros ni selección definitiva del modelo final. El alcance se limita a la presentación del baseline, tal como solicita la rúbrica: modelos iniciales y métricas de desempeño iniciales.

Modeling de objetivo ML 2: Predicción de demanda y stock crítico

Para abordar este segundo objetivo, enfocado en optimizar el abastecimiento del albergue y evitar quiebres de inventario, el problema se enmarcó principalmente como una tarea de regresión sobre series de tiempo, complementada con alertas de clasificación.

1. Preparación para el Modelado y División de Datos

Antes del entrenamiento, se filtró el dataset para aislar exclusivamente la información de los medicamentos oncológicos más importantes (Top 3) por volumen de consumo. Dado que los datos representan registros diarios, se utilizó una división estricta que respeta el orden cronológico (Time Series Split) para evitar el cruce de información del futuro hacia el pasado: el 80% más antiguo se usó para el conjunto de entrenamiento (Train) y el 20% más reciente para la evaluación (Test).

2. Modelos Evaluados (Baseline y Ensamblados)

Con el objetivo de proyectar con precisión la demanda a 7 y 14 días, se evaluaron cuatro algoritmos diferentes:

- Ridge Regression (Baseline): Modelo lineal clásico que aplica regularización L2. Excelente para evitar el sobreajuste inicial y lidiar con la multicolinealidad natural de los datos hospitalarios.
- Random Forest Regressor: Modelo de ensamble tipo Bagging que utiliza múltiples árboles de decisión paralelos para mejorar la robustez frente al modelo lineal base.
- Gradient Boosting Regressor: Ensamble iterativo (Boosting) que corrige paso a paso los errores de las predicciones anteriores, entrenado con una tasa de aprendizaje controlada.
- XGBoost Regressor: Una versión altamente optimizada del Gradient Boosting que incorpora penalizaciones matemáticas potentes, haciéndola ideal para ignorar variables ruidosas y anticipar picos repentinos.

3. Métricas de Desempeño Iniciales

La evaluación confirmó de manera contundente la superioridad de los algoritmos de tipo Boosting:

- Para la demanda a 7 días: El XGBoost fue el mejor modelo con un Error Cuadrático Medio (RMSE) de ~10.49 y un coeficiente R2-Score altísimo de ~0.988. Como contraste, el baseline lineal (Ridge) obtuvo un RMSE bastante superior de ~16.82.
- Para la demanda a 14 días: El XGBoost mantuvo su primer lugar con un RMSE de ~12.46 y un R2-Score de ~0.995.


Métricas de Error - Predicción a 7 Días

	MAE	MSE	RMSE	R2-Score
Ridge Regression	12.4269	273.8308	16.5478	0.9704
Random Forest	10.3226	238.0202	15.4279	0.9743
Gradient Boosting	8.6099	165.2078	12.8533	0.9821
XGBoost	6.8124	105.0866	10.2512	0.9886

Métricas de Error - Predicción a 14 Días


	MAE	MSE	RMSE	R2-Score
Ridge Regression	13.0257	287.0056	16.9412	0.9923
Random Forest	10.4015	223.6523	14.955	0.994
Gradient Boosting	9.8454	195.4939	13.9819	0.9947
XGBoost	5.8875	80.327	8.9625	0.9978

Desempeño Predictivo: Stock Real vs. Stock Predicho (7 días)




4. Justificación del Modelo Seleccionado

Se seleccionó oficialmente el XGBoost como el motor predictivo principal del sistema debido a su excepcional capacidad de capturar la inercia temporal y la varianza logística de ALDIMI, así mismo para el presente proyecto no presenta una varianza elevada en frente a coste computacional de los otros modelos, por lo que basándonos en metricas XGBoost se presenta como el modelo más funcional para el presente caso. Al explorar la interpretación del modelo, se validó lógicamente que las variables de rezago temporal (como el consumo promedio de los últimos 7 y 14 días y las salidas recientes de stock) son los predictores determinantes de las necesidades futuras.




Curvas de Aprendizaje para Predicción a 7 Días



5. Demostración Predictiva y Dashboard

Para aterrizar los hallazgos matemáticos en una herramienta de negocio útil, se generó un pronóstico binario complementario y sus probabilidades subyacentes, buscando anticipar días específicos en "estado crítico". Esto demuestra que la gestión de inventario puede abandonar la reposición reactiva y transicionar a un esquema proactivo.

Dashboard Preliminar de Predicciones de Stock Crítico



2.5. Evaluation

La fase de evaluación tuvo como finalidad analizar si los modelos desarrollados cumplen con los criterios técnicos definidos para el proyecto ALDIMI-Predict. Esta evaluación se realizó de manera separada para los dos objetivos de Machine Learning: el Dataset 1, orientado a la clasificación del nivel de prioridad de atención del paciente, y el Dataset 2, orientado a la predicción de demanda de insumos y alertas de stock crítico.

2.5.1. Evaluación del Dataset 1: Clasificación del nivel de prioridad de atención

Para el Dataset 1, el objetivo fue evaluar el desempeño del modelo encargado de clasificar el **nivel_prioridad** del paciente en tres categorías: bajo, medio y alto. Debido a la naturaleza del problema, la evaluación no se centró únicamente en el accuracy general, sino principalmente en la capacidad del modelo para identificar correctamente a los pacientes de prioridad alta.

El modelo finalmente seleccionado fue un Random Forest Classifier optimizado mediante búsqueda de hiperparámetros. Además, se aplicó una calibración de umbral para la clase alta, utilizando un umbral de 0.59. Esta calibración se realizó con el propósito de reducir los falsos negativos clínicamente críticos, es decir, aquellos casos donde un paciente realmente de prioridad alta podría ser clasificado como prioridad baja.

En el conjunto de prueba, el modelo obtuvo un recall de la clase alta de 0.8632, superando el criterio mínimo esperado de 0.85. Asimismo, alcanzó un Macro F1-score de 0.8791, superior al criterio mínimo de 0.80. Estos resultados muestran que el modelo mantiene un rendimiento equilibrado entre clases, sin descuidar la detección de pacientes de mayor prioridad.

<Insertar Tabla 1. Métricas finales del modelo Random Forest calibrado para Dataset 1>

La matriz de confusión final del modelo Random Forest con umbral calibrado fue la siguiente:

Real / Predicho	Bajo	Medio	Alto
Bajo	302	29	0
Medio	11	311	41
Alto	0	42	265

El resultado más importante de esta matriz es que no existen casos de pacientes reales de prioridad alta clasificados como prioridad baja. Es decir, el modelo obtuvo 0 errores críticos del tipo alto → bajo. Esto es relevante porque, en el contexto del proyecto, el error más peligroso no es clasificar de forma preventiva a un paciente como más grave, sino subestimar a un paciente que realmente requiere atención prioritaria.

También se observa que los errores restantes ocurren principalmente entre clases cercanas. Por ejemplo, algunos pacientes de prioridad alta fueron clasificados como prioridad media, y algunos pacientes de prioridad media fueron clasificados como prioridad alta. Aunque estos errores deben seguir siendo monitoreados, son menos graves que clasificar un paciente de prioridad alta como baja, ya que no implican una desatención extrema.

En cuanto a la interpretabilidad del modelo, el Random Forest permite analizar la importancia de las variables utilizadas en la clasificación. Se espera que las variables más influyentes estén relacionadas con la severidad clínica del paciente, como el estadio, la profundidad del tumor, la presencia de metástasis, los ganglios afectados, la anemia, la pérdida de peso, el estado nutricional, el dolor, el estado funcional y la necesidad de tratamientos complejos. Estas variables son coherentes con los hallazgos del EDA, donde se observó que el nivel de prioridad está más relacionado con variables clínicas y de estado del paciente que con variables demográficas.

Como análisis complementario, se recomienda incluir la curva ROC-AUC multiclase o una evaluación One-vs-Rest si se cuenta con las probabilidades por clase. Sin embargo, para

este problema, la métrica más importante sigue siendo el recall de la clase alta, porque está directamente vinculada al riesgo de no identificar pacientes que requieren atención prioritaria.

2.5.2. Evaluación del Dataset 2: Predicción de demanda y stock crítico

Para el Dataset 2, el objetivo fue evaluar modelos de regresión orientados a predecir la demanda futura de medicamentos e insumos a 7 y 14 días. A diferencia del Dataset 1, este problema tiene una naturaleza temporal, por lo que la evaluación se realizó respetando el orden cronológico de los datos.

El modelo avanzado seleccionado para este objetivo fue XGBoost Regressor, optimizado mediante búsqueda de hiperparámetros y validación temporal con `TimeSeriesSplit`. Este enfoque permitió evitar fuga de información del futuro hacia el pasado, lo cual es fundamental en problemas de series temporales.

Para la predicción de demanda a 7 días, el modelo obtuvo los siguientes resultados promedio:

Horizonte	MAE	RMSE	MAPE robusto
7 días	16.0345	23.1699	34.67%

El MAPE de 7 días fue superior al umbral ideal planteado inicialmente. Esto se explica porque, en horizontes cortos y demandas pequeñas, el MAPE puede volverse muy sensible a variaciones reducidas en valores absolutos. Por ello, en este caso también se consideran métricas como MAE y RMSE para interpretar el error desde una perspectiva operativa.

Para la predicción de demanda a 14 días, el modelo obtuvo los siguientes resultados:

Horizonte	MAE	RMSE	MAPE robusto
14 días	18.9470	30.4306	14.81%

En este horizonte, el modelo cumple con el criterio esperado, ya que el MAPE robusto fue de 14.81%, por debajo del umbral máximo de 20% definido para la predicción a mediano plazo. Esto indica que el modelo es útil para apoyar decisiones de reposición, compra o solicitud de donaciones con mayor anticipación.

Además de la predicción de demanda, el Dataset 2 permite generar alertas de stock crítico. Estas alertas se calculan comparando el stock actual con la demanda proyectada. Si el

stock disponible no cubre la demanda estimada, el sistema activa una alerta para que el equipo responsable pueda planificar reposición o priorizar recursos.

2.5.3. Conclusión de la evaluación

La evaluación muestra que ambos modelos cumplen funciones complementarias dentro de ALDIMI-Predict. El modelo del Dataset 1 permite identificar pacientes con mayor prioridad de atención, mientras que el modelo del Dataset 2 permite anticipar necesidades de medicamentos e insumos.

En el Dataset 1, el Random Forest calibrado logró reducir el error clínicamente más delicado: clasificar pacientes de prioridad alta como baja. En el Dataset 2, XGBoost mostró un buen desempeño en la predicción de demanda a 14 días, permitiendo anticipar necesidades logísticas con mayor margen de acción. En conjunto, ambos modelos aportan valor predictivo al sistema, ya que permiten pasar de una gestión reactiva a una gestión preventiva basada en datos.

3. Implementación y Despliegue (MLOps)

3.1. Arquitectura del modelo

La implementación del ecosistema ALDIMI-Predict se organizó bajo una arquitectura modular en Python, separando los componentes de datos, modelos, pipeline, base de datos, dashboard y pruebas. Esta separación permite que el sistema sea más mantenible, escalable y fácil de integrar con otros módulos del ecosistema.

La estructura principal del proyecto contempla una carpeta de datos, una base SQLite compartida, modelos entrenados en formato serializado, scripts de conexión a base de datos, un pipeline de inferencia y una aplicación de visualización desarrollada en Streamlit.

El flujo general del sistema es el siguiente:

1. Los datos clínicos y sociales del paciente ingresan al sistema.
2. El pipeline valida la calidad del dato.
3. Se aplican las transformaciones de preprocesamiento y feature engineering.
4. El modelo de clasificación predice el nivel de prioridad del paciente.
5. La predicción se almacena en la base de datos común.
6. El censo del albergue se recalcula usando las prioridades de los pacientes activos.
7. El modelo de demanda estima necesidades futuras de medicamentos e insumos.
8. Las alertas y resultados se visualizan en el dashboard.

3.2. Pipeline de datos desde la base de datos común

El pipeline de datos fue implementado para conectar la base de datos común con los modelos de Machine Learning. La base de datos utilizada es `aldimi_shared.db`, gestionada mediante SQLite y SQLAlchemy ORM.

Para el Dataset 1, los registros clínicos y sociales de los pacientes se almacenan en la tabla `paciente_evaluaciones_ocr`. Luego, el pipeline lee los registros que aún no cuentan con predicción, aplica el mismo preprocesamiento usado durante el entrenamiento y ejecuta el modelo Random Forest optimizado. El resultado se guarda en la tabla `paciente_predicciones_prioridad`, incluyendo la prioridad predicha, las probabilidades por clase y el umbral aplicado.

Para el Dataset 2, el sistema utiliza la información del censo de pacientes activos, junto con los datos de inventario y consumo histórico, para generar predicciones de demanda a 7 y 14 días. Estas predicciones se almacenan en la tabla `insumo_predicciones`, donde también se registran los indicadores de stock crítico.

<Insertar Figura 7. Esquema relacional de la base de datos común>

Las tablas principales del sistema son:

Tabla	Descripción
<code>paciente_evaluaciones_ocr</code>	Contiene los datos clínicos y sociales del paciente.
<code>paciente_predicciones_prioridad</code>	Almacena la prioridad predicha por el modelo de clasificación.
<code>insumo_inventario</code>	Registra información actual de stock, consumo y características de los insumos.
<code>insumo_predicciones</code>	Guarda la demanda proyectada y las alertas de stock crítico.

3.3. Dashboard de visualización

El dashboard fue desarrollado en Streamlit y está orientado a apoyar la toma de decisiones de los directivos y responsables operativos de ALDIMI. La herramienta permite consultar tanto la situación clínica de los pacientes como el estado logístico del inventario.

El dashboard cuenta con tres vistas principales.

Vista 1: Panel de gestión de pacientes

Esta vista permite ingresar los datos clínicos y sociales de un paciente, simulando la información recibida desde el módulo OCR. Después del ingreso, el pipeline ejecuta la predicción en tiempo real y muestra la prioridad asignada mediante un sistema visual de colores:

Prioridad	Color
Bajo	Verde
Medio	Naranja
Alto	Rojo

Además, se muestra una tabla con el censo activo de pacientes y sus prioridades asignadas.

Vista 2: Panel logístico y de inventario

Esta vista permite revisar los medicamentos e insumos críticos considerados en el proyecto. Para cada insumo, se muestran métricas como stock actual, consumo diario promedio, demanda proyectada a 7 días y demanda proyectada a 14 días.

También se incluye un gráfico interactivo que muestra la evolución histórica del consumo y del stock, junto con las proyecciones generadas por el modelo.

Vista 3: Módulo de alertas de stock crítico

Esta vista muestra los medicamentos o insumos que podrían entrar en riesgo de desabastecimiento. El sistema utiliza un semáforo de cobertura:

Estado	Criterio
Rojo - Crítico	Cobertura menor a 7 días

Naranja - Cobertura entre 7 y 14 días
Riesgo

Verde - Seguro Cobertura mayor o igual a 14
días

Esta visualización permite que ALDIMI identifique con anticipación qué recursos requieren reposición, compra o solicitud de donación.

3.4. Verificación y calidad del despliegue

Para validar el funcionamiento técnico del sistema, se implementaron pruebas automatizadas con `unittest`. Estas pruebas verifican operaciones básicas de base de datos, integridad referencial, validación de datos de entrada y ejecución del pipeline completo.

Se ejecutaron pruebas de integración y pruebas del pipeline, obteniendo como resultado:

Ran 6 tests in 1.182s

OK

Este resultado indica que el sistema puede ejecutar correctamente el flujo principal de lectura, procesamiento, inferencia y almacenamiento de resultados.

4. Análisis de Impacto ODS y Ética de Datos

4.1. Relación con los ODS

El proyecto ALDIMI-Predict se relaciona principalmente con los ODS 2 y 3, debido a su orientación hacia la gestión de recursos, la atención de pacientes y el soporte nutricional en un contexto de vulnerabilidad social.

ODS 2: Hambre cero

El ODS 2 se vincula con el proyecto porque una parte importante del sistema está orientada al seguimiento de suplementos nutricionales y recursos de soporte alimentario. En pacientes oncológicos, especialmente aquellos con cáncer gástrico, el estado nutricional es

una variable crítica, ya que la pérdida de peso, la dificultad para alimentarse y la desnutrición pueden aumentar la prioridad de atención.

El sistema contribuye a este ODS porque permite anticipar la demanda de suplementos nutricionales y evitar desabastecimientos. De esta manera, ALDIMI puede planificar mejor la disponibilidad de recursos alimentarios para los pacientes alojados o acompañados por la institución.

Como indicador de impacto, se propone medir:

Reducción de quiebres de stock nutricional (%) =

$$\frac{(\text{quiebres antes del sistema} - \text{quiebres después del sistema})}{\text{quiebres antes del sistema}} \times 100$$

También se puede medir:

Cobertura nutricional proyectada =

$$\frac{\text{stock disponible de suplementos}}{\text{demanda proyectada de suplementos a 7 o 14 días}}$$

En esta etapa, al trabajar con datos sintéticos, no se afirma todavía un porcentaje real de reducción del desperdicio o desabastecimiento. Sin embargo, el sistema deja preparada la estructura para medir este impacto cuando se conecte con datos operativos reales.

ODS 3: Salud y bienestar

El ODS 3 se relaciona directamente con el modelo de clasificación de prioridad de atención. El sistema permite identificar pacientes que requieren mayor seguimiento clínico, nutricional o social, reduciendo el riesgo de que casos graves pasen desapercibidos.

El modelo de clasificación contribuye a una atención más oportuna porque prioriza a pacientes con señales de mayor severidad, como estadio avanzado, metástasis, anemia, pérdida de peso, dolor alto, deterioro nutricional o bajo estado funcional.

Como indicador de impacto, se propone medir:

Tasa de detección de pacientes de alta prioridad =

$$\frac{\text{pacientes de prioridad alta correctamente identificados}}{\text{total de pacientes reales de prioridad alta}}$$

En la evaluación realizada, el modelo Random Forest calibrado alcanzó un recall de clase alta superior al criterio mínimo esperado, lo que muestra que el sistema puede apoyar la detección temprana de pacientes con mayor necesidad de atención.

4.2. Sesgos y ética de datos

El proyecto trabaja con datos sintéticos, lo cual permite proteger la privacidad de pacientes reales. Esta decisión es importante porque los datos de salud son altamente sensibles y no deben exponerse sin consentimiento ni mecanismos adecuados de anonimización.

Sin embargo, el uso de datos sintéticos no elimina por completo el riesgo de sesgo. Los sesgos pueden aparecer si las reglas de generación de datos representan de forma desigual a ciertos grupos de pacientes o si el modelo aprende patrones que favorecen más a un grupo que a otro.

Entre los posibles sesgos se consideran:

1. Sesgo por sexo: el modelo podría tener mejor desempeño en pacientes masculinos o femeninos si la distribución de casos no es equilibrada.
2. Sesgo por región de procedencia: los pacientes de regiones menos representadas podrían recibir predicciones menos precisas.
3. Sesgo por vulnerabilidad social: existe el riesgo de que las variables sociales influyan de manera inadecuada en la prioridad clínica.
4. Sesgo por edad: si el dataset contiene mayor presencia de adultos mayores, el modelo podría generalizar peor en pacientes más jóvenes.
5. Sesgo por acceso a salud: pacientes con mayor dificultad de acceso podrían ser interpretados como más graves o menos graves si no se separa adecuadamente el riesgo clínico del contexto social.

Para mitigar estos riesgos, se aplicaron varias decisiones metodológicas. Primero, se separaron variables clínicas, sociales y demográficas durante el EDA para entender su comportamiento. Segundo, se analizó la asociación de las variables sociales con la prioridad, observando que la prioridad está más relacionada con variables clínicas y de estado del paciente. Tercero, se priorizó la interpretabilidad del modelo mediante el análisis de importancia de variables. Finalmente, se recomienda evaluar métricas por subgrupos antes de cualquier uso real del sistema.

Desde una perspectiva ética, ALDIMI-Predict no debe reemplazar el criterio del personal médico o social. El sistema debe utilizarse como una herramienta de apoyo a la toma de decisiones, permitiendo ordenar la atención y anticipar necesidades, pero siempre con revisión humana.

5. Confluencia con el Ecosistema ALDIMI Core AI

5.1. Descripción técnica de la integración

La confluencia con el ecosistema ALDIMI Core AI se realiza mediante una base de datos común y un pipeline de inferencia conectado a los módulos desarrollados por los compañeros del curso de IA.

El flujo inicia cuando el módulo de IA procesa documentos o formularios clínicos mediante OCR. La información extraída se estructura y se almacena en la tabla `paciente_evaluaciones_ocr`. Esta tabla actúa como punto de entrada para el modelo de Machine Learning del Dataset 1.

Luego, el pipeline de ALDIMI-Predict lee los registros pendientes de predicción, aplica las transformaciones necesarias y ejecuta el modelo de clasificación. El resultado se almacena en `paciente_predicciones_prioridad`, incluyendo la prioridad predicha y las probabilidades asociadas a cada clase.

Después de esta predicción, el sistema recalcula el censo del albergue. Esta información agregada se convierte en entrada para el Dataset 2, que estima la demanda futura de insumos y medicamentos. Finalmente, las predicciones logísticas se almacenan en `insumo_predicciones` y se muestran en el dashboard.

El flujo completo puede representarse de la siguiente manera:

Módulo OCR / IA



`paciente_evaluaciones_ocr`



Pipeline de preprocesamiento ML



Modelo 1: Clasificación de prioridad



`paciente_predicciones_prioridad`



Censo clínico-operativo del albergue



Modelo 2: Predicción de demanda y stock



`insumo_predicciones`



Dashboard ALDIMI-Predict

5.2. Valor de la integración entre módulos

La integración entre los módulos permite que el sistema no funcione como modelos aislados, sino como un ecosistema predictivo. El modelo de clasificación transforma datos clínicos y sociales en un nivel de prioridad. Luego, esa prioridad se utiliza para recalcular el censo de pacientes y alimentar la predicción de demanda de insumos.

Esto permite que el sistema conecte el riesgo del paciente con la planificación logística. Por ejemplo, si aumenta la cantidad de pacientes con prioridad alta, desnutrición, anemia o tratamiento paliativo, el sistema puede anticipar una mayor demanda de suplementos nutricionales, medicamentos de soporte, analgésicos o insumos de curación.

5.3. Lecciones aprendidas en la integración

Durante la integración se identificaron varias lecciones importantes:

1. La estandarización de variables es fundamental.
El modelo solo puede funcionar correctamente si las variables recibidas desde el módulo OCR tienen los mismos nombres, formatos y categorías que las utilizadas durante el entrenamiento.
2. El preprocesamiento debe ser idéntico en entrenamiento e inferencia.
Las reglas de imputación, codificación ordinal, codificación binaria y creación de variables derivadas deben mantenerse iguales para evitar inconsistencias.
3. La base de datos común facilita la trazabilidad.
Al guardar tanto la evaluación del paciente como la predicción generada, el sistema permite auditar qué datos ingresaron y qué resultado produjo el modelo.
4. La integración clínica y logística aumenta el valor del sistema.
La predicción de prioridad por sí sola ayuda a ordenar pacientes, pero su verdadero valor aumenta cuando alimenta el modelo de demanda y permite anticipar recursos.
5. La automatización requiere validaciones estrictas.
Antes de ejecutar inferencias, el sistema debe validar fechas, rangos de edad, hemoglobina y consistencia de categorías, para evitar predicciones basadas en datos erróneos.
6. El modelo debe apoyar, no reemplazar, la decisión humana.
Debido a que se trabaja con salud, las predicciones deben interpretarse como recomendaciones de apoyo y no como decisiones automáticas definitivas.

6. Anexo

Repositorio del proyecto:

<https://github.com/Machiz/Aldimi-Project>

Diccionario de datos final

El diccionario de datos final debe incluir las variables utilizadas en ambos datasets.

Dataset 1: Evaluaciones de pacientes

Variable	Descripción	Uso
<code>evaluacion_id</code>	Identificador único de la evaluación	Identificación
<code>paciente_id</code>	Identificador del paciente	Seguimiento
<code>edad</code>	Edad del paciente	Predictor
<code>sexo</code>	Sexo del paciente	Predictor demográfico
<code>region_procedencia</code>	Región de procedencia	Predictor social
<code>nivel_vulnerabilidad</code>	Nivel de vulnerabilidad social	Predictor social
<code>estadio</code>	Estadio clínico del cáncer	Predictor clínico
<code>grado_histologico</code>	Grado histológico del tumor	Predictor clínico
<code>ganglios_afectados</code>	Número de ganglios afectados	Predictor clínico
<code>metastasis</code>	Presencia de metástasis	Predictor clínico

perdida_peso_kg	Pérdida de peso en kg	Predictor clínico/nutricional
hemoglobina	Nivel de hemoglobina	Predictor clínico
anemia	Presencia de anemia	Predictor clínico
dolor	Nivel de dolor	Predictor sintomático
estado_nutricional	Estado nutricional del paciente	Predictor nutricional
estado_funcional	Nivel de autonomía funcional	Predictor clínico
requiere_quimioterapia	Indica si requiere quimioterapia	Predictor terapéutico
requiere_soporte_nutricional	Indica si requiere soporte nutricional	Predictor terapéutico
nivel_prioridad	Nivel real de prioridad	Variable objetivo
prioridad_predicha	Nivel estimado por el modelo	Salida del sistema

Dataset 2: Demanda y stock de insumos

Variable	Descripción	Uso
item_id	Identificador del insumo	Identificación

item_nombre	Nombre del medicamento o insumo	Identificación
stock_actual	Stock disponible	Predictor operativo
stock_minimo	Stock mínimo requerido	Predictor operativo
consumo_diario	Consumo diario registrado	Predictor temporal
consumo_lag_1	Consumo del día anterior	Predictor temporal
consumo_lag_7	Consumo de hace 7 días	Predictor temporal
consumo_promedio_7d	Promedio móvil de consumo de 7 días	Predictor temporal
consumo_promedio_14d	Promedio móvil de consumo de 14 días	Predictor temporal
demanda_proyectada_7d	Demanda estimada para 7 días	Salida del modelo
demanda_proyectada_14d	Demanda estimada para 14 días	Salida del modelo
dias_cobertura	Días que cubre el stock actual	Indicador de gestión
stock_critico	Indica riesgo general de stock crítico	Alerta

stock_critico_7d Indica riesgo de stock crítico a 7 días Alerta

stock_critico_14d Indica riesgo de stock crítico a 14 días Alerta

7. Bibliografía

ALDIMI. (s.f.). *Nosotros*. <https://aldimi.pe/nosotros/>

Centro Nacional de Epidemiología, Prevención y Control de Enfermedades. (2023). *Sala situacional de cáncer en el Perú: SE 52-2023*. Ministerio de Salud del Perú. <https://www.dge.gob.pe/portal/docs/vigilancia/sala/2023/SE52/cancer.pdf>

Infobae. (2026, 3 de febrero). *Día Mundial contra el Cáncer: Perú registra más de 72 mil nuevos casos y casi 36 mil muertes al año*. <https://www.infobae.com/peru/2026/02/03/dia-mundial-contra-el-cancer-peru-registra-mas-d-e-72-mil-nuevos-casos-y-casi-36-mil-muertes-al-ano/>

Guia de practica clinica para el cancer gastrico (2024) INEN <https://portal.inen.sld.pe/wp-content/uploads/2024/05/RJ-N%C2%B0-116-2024-J-INEN.pdf>

<https://colab.research.google.com/drive/108ri2XU1kT1-3U-7ppqkIGIB6ITvUBi#scrollTo=R0uG4tNhNzhS&uniqifier=1>

https://colab.research.google.com/drive/1-EF3FOdqX2u_UrCq2hUpYoRIg2AlBwo0#scrollTo=6WNZuYQWO-7x&uniqifier=1

<https://colab.research.google.com/drive/1tPeUaf0BbrjuRWyOJwTgWa2Ed8eVmCyt#scrollTo=ahIDEDpOrUsa&uniqifier=1>